

北京理工大学

本科生毕业设计（论文）

基于数据库的文件系统设计与实现

Design and Implementation of File System Based on Database

学 院：	计算机学院
专 业：	计算机科学与技术
班 级：	07111906
学生姓名：	陈林峰
学 号：	1120192739
指导教师：	陆慧梅

2023 年 5 月 22 日

原创性声明

本人郑重声明：所呈交的毕业设计（论文），是本人在指导老师的指导下独立进行研究所取得的成果。除文中已经注明引用的内容外，本文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

特此申明。

本人签名：

日期：

年

月

日

关于使用授权的声明

本人完全了解北京理工大学有关保管、使用毕业设计（论文）的规定，其中包括：①学校有权保管、并向有关部门送交本毕业设计（论文）的原件与复印件；②学校可以采用影印、缩印或其它复制手段复制并保存本毕业设计（论文）；③学校可允许本毕业设计（论文）被查阅或借阅；④学校可以学术交流为目的，复制赠送和交换本毕业设计（论文）；⑤学校可以公布本毕业设计（论文）的全部或部分内容。

本人签名：

日期：

年

月

日

指导老师签名：

日期：

年

月

日

基于数据库的文件系统设计与实现

摘 要

文件系统在发展过程中一直在借鉴数据库的相关特性，诸如日志、事务、高效索引机制等。但在一个新的文件系统中引入这些特性是一个复杂且容易出现错误的挑战，一方面这些特性本身就需要复杂的数据结构和算法支撑，另一方面，这些特性需要在文件系统投入使用前进行完整的测试和分析。而在数据库中，这些特性是其本身就具备的，并且已经经过了长时间的实际应用得到了检验。如何将数据库的功能与文件系统进行有机结合是一直是一项复杂但有潜力的工作。目前大多数的解决方案集中于将数据库的特性移植到文件系统中，只有少部分的工作在探索如何将两者进行深度融合，以达到充分利用数据库功能的效果。在此基础上，本文选择基于键值数据库设计一个文件系统，探索如何平衡两者之间的差异，并充分利用数据库中的数据结构构建一个高效的、可扩展的文件系统结构。本文基于数据库 jammdb 实现了一个数据库文件系统 (database file system, DBFS), 并将其移植到了一个自行编写的操作系统 Alien OS 内核当中，同时为其实现了 linux 的 fuse 用户态接口。

实验结果表明，DBFS 的实现符合 POSIX 文件系统语义，并通过了其 92% 的测试。在元数据密集型测试中 DBFS 充分利用了数据库的高效数据结构，在文件查找、目录搜索等操作上达到了与常见的 ext 文件系统同一水平，DBFS 同样将数据库的事务特性融入到文件系统实现当中，使其在一些原子性操作上领先常见的文件系统。在读写性能测试中，得益于数据库的缓存机制，DBFS 也有不错的表现。总体而言，基于数据库的文件系统在保证了同时具有文件系统和数据库功能的前提下，大大简化了文件系统的开发难度，提高了文件系统的可扩展性。

关键词：文件系统；数据库；操作系统；VFS；数据库文件系统

Design and Implementation of File System Based on Database

Abstract

File systems have evolved with DB mechanisms like logging, transactions, and indexing. But introducing these features into a new file system is a complex and error-prone challenge, as they require complex data structures and algorithms to support them, and they need to be fully tested and analysed before the file system is put into use. In the case of databases, these features are inherent and have been tested over a long period of time in practice. It has always been a complex but promising task to combine the functionality of a database with a file system. Most solutions focus on porting DB features to file systems, while few explore deep integration. On this basis, this thesis chooses to design a file system based on a key-value database, exploring how to balance the differences between the two and make full use of the data structures in the database to build an efficient and scalable file system architecture. This thesis implements a database file system (DBFS) based on the database jammdb, and ports it to a self-written operating system, Alien OS kernel, and implements the linux fuse user state interface for it.

The experimental results show that the DBFS implementation conforms to POSIX file system semantics and passes 92% of its tests. In the metadata-intensive test, DBFS makes full use of the efficient data structure of the database and achieves the same level as the common ext file system in file lookup and directory search operations, DBFS also incorporates the transactional features of the database into the file system implementation, making it ahead of the common file system in some atomic operations. In the read/write performance test, DBFS also has good performance thanks to the caching mechanism of database. Overall, the database based file system greatly simplifies the development difficulty and improves the scalability of the file system under the premise of ensuring both file system and database functions.

Key Words: Filesystem;database;OS;VFS;database filesystem

目 录

摘 要	I
Abstract	II
第 1 章 绪论	1
1.1 研究背景	1
1.2 国内外研究现状	2
1.3 研究目的和意义	3
1.4 主要工作内容	4
1.5 文章结构	5
第 2 章 相关理论与方法	7
2.1 数据库	7
2.1.1 事务 (Transaction)	8
2.1.2 索引和缓存	8
2.1.3 并发	9
2.2 Linux 内核与文件系统	9
2.3 数据库文件系统实现技术与方法	10
2.4 编程语言	11
2.5 本章小结	12
第 3 章 DBFS 设计与实现	13
3.1 DBFS 的整体结构	13
3.2 数据库结构的分析	14
3.3 DBFS 的接口设计与核心结构	14
3.4 元信息管理与目录树构建	17
3.5 文件数据存储	20
3.6 数据库接口导出	21
3.7 小结	22
第 4 章 DBFS 的 fuse 实现与内核移植	24
4.1 linux 用户态 DBFS-Fuse 实现	24
4.2 Alien OS	26
4.3 VFS	27
4.4 DBFS 内核移植	29

4.5 性能优化	32
4.5.1 flush+sync_all	33
4.5.2 固定文件大小	33
4.5.3 调整块大小	34
4.6 小结	34
第 5 章 测试与分析	35
5.1 测试指标与其它文件系统	35
5.2 测试环境和准备	36
5.3 pjdftest POSIX 兼容性测试	37
5.3.1 结果说明	37
5.4 mdtest 元数据性能测试	37
5.5 fio 读写性能测试	39
5.5.1 分析	42
5.6 Filebench	43
5.7 Alien OS 的性能测试	45
5.8 小结	46
结 论	47
参考文献	49
附 录	51
附录 A linux 环境下 DBFS 的 fuse 使用	51
附录 B Alien OS	51
附录 C Fio 测试数据	51
致 谢	53

第 1 章 绪论

1.1 研究背景

计算机的文件系统是一种存储和组织计算机数据的方法，它使得对数据的访问和查找变得容易，文件系统使用文件和树形目录的抽象逻辑概念代替了硬盘和光盘等物理设备使用数据块的概念，用户使用文件系统来保存数据而不必关心数据实际保存在硬盘（或者光盘）的地址为多少的数据块上，只需要记住这个文件的所属目录和文件名。在写入新数据之前，用户不必关心硬盘上的哪个块地址没有被使用，硬盘上的存储空间管理（分配和释放）功能由文件系统自动完成，用户只需要记住数据被写入到了哪个文件中。随着时间的推移，存储需求不断变化，数据量不断增加，文件系统必须是可靠的、持久的、安全的、高效的、容错的和可扩展的^[1]，为了实现这些特性并跟上不断变化的计算需求和存储需求，不同的技术和文件系统随着时间的推移而被引入到操作系统中，但是绝大多数的文件系统实现仍然采用的是树状层次结构，提供给用户的接口仍然是 open,read/write 等。

在文件系统快速发展的同时，数据库系统同样也在随着需求的不断变化而快速迭代。数据库是以电子方式存储的系统数据集合，它可以包含任何类型的数据，包括文字、数字、图像、视频和文件。这些数据按一定的数据模型组织、描述和存储，具有较小冗余度、较高数据独立性和易扩展性，并可为各种用户共享。通常，数据库的实现以文件系统为基础，所有的数据库操作，如增删改查、备份等最后都会转换为对磁盘上文件的操作，但有时数据库并不想受到文件系统实现带来的影响，一个广泛的现象是许多数据库系统的实现都会包含一个缓存模块，以此来提高其性能和可靠性。除了一直占据主要地位的大型关系型数据库系统，如 Mysql、SQLserver 等，近年来也出现了一些嵌入式数据库和许多 nosql 数据库，这些数据库与传统的数据库相比，其对系统资源的占用更小^[2]，如 sqlite^[3]，其与应用程序运行在同一个地址空间中，而不是像 Mysql 那样存在服务器端和客户端的区别，同时，新兴的 nosql 数据库虽然功能不如传统的大型关系型数据库完善，但根据需求的变化，这些 nosql 数据库在一些专有领域也有着不错的表现。

从数据库和文件系统的发展来看，两者是在互相改进，共同发展，从两者的功能来看，他们都是存储数据的一种管理方式。一种可以充分利用两者优势的方案是

将数据库直接引入到文件系统中，让文件系统原生地具备数据库的能力，通过有效地结合两者的功能，使得用户在存储数据时不再担心原来那些可能会发生在传统文件系统中的数据丢失、数据错误问题。

1.2 国内外研究现状

早期，数据库系统的基础是底层的文件系统，许多管理数据的特性都只是在数据库系统上得到体现，而近年来，文件系统的设计开发中越来越借鉴了数据库相关技术的思想，二者不断融合发展。日志文件系统就是在借鉴数据库系统的日志和事务特性之后发展出的一种文件系统。在对文件系统进行修改时，需要进行很多操作，比如在扩展一个文件的大小时，需要对文件的元信息和磁盘元信息都需要修改，这些操作可能中途被打断，但是，理论上这些操作不是不可中断的。如果操作被打断，就可能造成文件系统出现不一致的状态，虽然可以使用一些工具对这些情况进行修复，如 `fsck`，但这些工具在修复时需要扫描整个磁盘，繁琐且速度较慢。日志文件系统在修改磁盘数据时利用日志信息记录修改过程，如果文件系统发生崩溃，重启后只需要根据日志信息就可以恢复数据从而保证数据的一致性和完整性。发展较早的日志文件系统 JFS^[4]、XFS^[5] 如今在某些系统上仍然广泛使用。而较新的 Btrfs^[6]、Ext4^[7]、NTFS 等具有日志功能的文件系统在服务器系统与桌面系统上占据着主要地位。除了对数据库的日志和简单事务的借鉴之外，许多适应新需求的文件系统实现在设计中会直接包含事务 ACID 特性的设计，exF2FS^[8] 是一个事务性的日志文件系统，其允许事务跨越多个文件，应用程序可以显式指定与事务关联的文件，同时其允许使用少量内存执行事务并在一个事务中封装多个更新。DurableFS^[9] 提供了一种受限制的事务形式：文件打开和关闭之间的操作自动形成具有原子性和持久性保证的事务。

一些文件系统的实现不再局限于在文件系统的设计上引入数据库系统的特性，而是选择直接基于数据库系统进行文件系统的实现，考虑到数据库系统提供的特性的实现复杂度，这种方案在实施难度上要远远小于重新设计文件系统。IFS^[10] 是一个基于关系型数据库 POSTGRES 实现的文件系统，其向用户提供事务特性以及时间旅行功能，同时其使用多张关系表来构建层级文件系统以最大限度地支持传统 POSIX 接口。Oracle iFS 是一个运行在数据库之上的文件系统，实质上，Oracle iFS 提供了文件系统和数据库之间的范式转换，同时提高了一些高级搜索和数据备份功能。国内

学者^[11]将 Oracle iFS 移植到 linux 的 VFS 模块中使得用户对其使用就如原有的文件系统一样，并且将基于内容分类、关联访问、基于内容的访问、版本控制等功能扩展到 VFS 中。AMINO^[12]是一个具有 ACID 语义的文件系统，其使用 Berkeley Database 作为后备存储，将一个易于使用但功能强大的嵌套事务 API 导出到用户空间。应用程序可以开始、提交和中止事务，同时其设计了一个简单的 API，使协作进程能够共享事务。使用相同的 API，单个应用程序可以支持多个并发事务。该文件系统不仅为应用程序提供了 ACID 的额外好处，在性能方面也与 ext3 相当。

将数据库的功能引入到文件系统的工作依然在不断进行当中，但是将两者进行有机结合的工作近年来却止步不前，一方面，数据库系统已经变得愈加复杂，很多数据库已经不仅仅是一个独立的程序，将位于用户态的庞大的数据库系统移植到内核中并与文件系统交互看起来是一件不可能的事；另一方面，之前的许多工作发现，基于数据库的文件系统导致了不必要的性能损失，这导致了大多数学者将重心移到了文件系统的设计之上而不再关注如何更进一步地改善两者的关系从而提高性能。

如今数据库的发展愈加迅速，其速度远远超过了文件系统的发展。同时，许多单机数据库的出现也让移植数据库到内核中，并将其与文件系统结合变得简单，这些单机数据库不仅具备与那些大型数据库相当的性能，同时还具备良好的移植性。

1.3 研究目的和意义

基于上述的研究背景和国内外现状，本文基于键值对数据库设计了一个文件系统。基于数据库的文件系统的可以带来很多好处，例如，数据库提供了高效的查找算法和缓存机制，可以加快文件访问速度；同时，数据库也提供了高级特性，比如备份、事务等；此外，使用数据库还可以简化文件系统的实现，使得开发者不再需要关注磁盘的具体布局，不需要重复编写数据库中已经具备的功能，提高代码的可维护性和可扩展性。

本研究旨在通过将文件系统和数据库系统相结合，充分发挥两者的优势，实现高效、可扩展、易管理的文件存储与管理系统。具体地，通过将文件和相关的元数据存储到数据库中，利用数据库系统的索引机制实现高效的文件检索和访问，同时设计文件在数据库中的存储方式，实现文件的高效存储和管理，在用户态，本文也提供数据库操作的直接抽象使得用户也可以直接使用数据库的接口进行数据的存储和访问，这种设计不仅可以提高系统的性能和可扩展性，还可以提高系统的可靠性和

安全性。

基于数据库的文件系统设计与实现的意义在于可以重用数据库的基础设施，探索如何将数据库与文件系统进行深度融合、如何充分利用来自数据库的特性。

1.4 主要工作内容

基于数据库的文件系统设计与实现的主要工作内容是将数据库的存储和管理思想结合到文件系统中，设计并实现一个具有数据库特性的文件系统，实现对文件的高效管理和查询以及存储。具体研究内容包括：

1. 数据库技术与文件系统结合：将数据库的基本概念、数据结构、数据存储和管理技术与文件系统的数据组织、存储和访问方式相结合，构建一个具有数据库特性的文件系统；
2. 文件管理与查询优化：设计文件系统，包括文件的存储、读取、修改、删除等操作，并优化文件的查询性能，通过对文件元数据的索引和优化算法等手段，实现对文件的快速查询和检索；
3. 数据一致性与事务管理：研究文件系统和数据库之间的数据一致性问题，实现事务管理功能，确保数据的完整性和一致性；
4. 安全性与权限管理：根据 linux 系统的文件权限检查机制，在文件系统中实现相关的检查逻辑，保证文件系统具有正确的安全性；
5. 系统实现与性能测试：基于上述研究内容，设计并实现一个完整的基于数据库的文件系统原型，并进行性能测试和优化，验证其可行性和实用性；

本文基于一个 key-value 类型的数据库 jammdb，设计并实现了一个数据库文件系统 (database file system, DBFS)。本文在一个自己编写的类 linux 操作系统 Alien OS 内核中移植了 DBFS，DBFS 支持标准的文件系统操作，以及其他有用的扩展，如扩展属性、ACL、事务接口。同时本文为 DBFS 实现了 linux 的 fuse 用户态接口，使其可以运行于 linux 系统上并与其它文件系统进行对比。为了实现 DBFS，本文抽象了数据库 jammdb 的底层接口，并为 DBFS 实现了一层操作系统无关的接口。DBFS 的基本操作是键值对的插入删除，而不是位图和分配表等低级对象，因此它很容易扩

展；DBFS 围绕其文件系统操作使用了数据库事务，这确保了 DBFS 操作的可靠性。DBFS 还将事务 API 导出到用户级进程，允许用户原子地完成数据的存储。

本项目的实现使用 rust 语言完成，在实现中，本文没有选择功能强大的数据库来作为文件系统实现的底层支持，而是选择了一个简单的 key-value 数据库。同时，因为使用 rust 来完成所有实现，而将这些实现直接放到 linux 中目前还不可行，因此本文为此实现了一个简单的类 linux 操作系统，并将 DBFS 移植到此系统上。同时为了获得它的性能数据和实现的正确性，本文在 linux 系统上为 DBFS 的 fuse 实现使用了几个常见的性能测试工具以及几个常见的文件系统进行了测试。

总的来说，本项目总共会包含以下几个项目：

1. Alien: 使用 rust 实现的简单类 linux 操作系统，验证将数据库文件系统移植到操作系统内核的可能性；
2. jammdb: key-value 数据库，本文选择使用的数据库；
3. rvfs: rust 写的 vfs 框架，主要参考 linux 中的 vfs, 用在 Alien OS 中；
4. dbfs: 本文设计实现的数据库文件系统，同时包含了用户态 fuse 实现；
5. dbop: 数据库操作抽象，一种在操作系统中导出数据库接口的方法；

1.5 文章结构

本文的结构安排如下：

第一章，给出本课题的研究背景和意义，并概述国内外的研究现状，本文的主要工作内容以及文章的写作结构。

在第二章，介绍数据库、文件系统、操作系统内核以及数据库文件系统相关的领域知识以及这些系统如何协同工作，同时说明本文选择的编程语言。

在第三章，详细介绍本次实现的数据库文件系统使用到的数据库，以及整个数据库文件系统的架构和设计方案。

在第四章，介绍数据库文件系统的 fuse 接口适配，以及将数据库文件系统接入到操作系统内核的方案。

在第五章，对本文所设计的系统进行实验测试，以评估其性能和可靠性，以及与其他相关系统进行比较分析，主要的测试讨论位于用户态的 fuse 实现，并简要介

绍接入内核的测试。

在第六章，总结全文，并指出未来进一步的研究方向。

第 2 章 相关理论与方法

本章介绍了本项目设计到的相关理论和方法，并对数据库文件系统的实现技术进行深入研究和总结。2.1 节主要介绍数据库系统的一些概念，比如事务，索引，缓存，并发等；2.2 节主要介绍操作系统和文件系统的关系，文件系统在内核中扮演的角色，并详细介绍 VFS 的数据结构与方法；2.3 节介绍数据库文件系统的实现技术和方法，阐述将数据库作为文件系统存储引擎并将其移植到内核中的困难之处。

2.1 数据库

在计算机应用中，数据是非常重要的资源，其管理和处理对应用系统的正常运行和业务发展至关重要。但是，传统的数据处理方式往往是以文件为基础的，这往往会导致许多问题：

1. 数据格式不统一：以文件方式组织的数据在逻辑上更简单，但可扩展性差，访问这种数据的程序需要了解数据的具体组织格式，这就导致面对不同的数据应用程序就需要实现不同的读取方法；
2. 数据冗余：同一份数据可能会被存储在不同的文件中，导致数据冗余，增加数据存储和维护的成本；
3. 数据不一致：当多个应用程序同时修改数据时，可能会导致数据不一致，出现错误或者异常情况；
4. 数据共享困难：文件系统无法提供有效的数据共享机制，导致数据共享困难，降低了系统的协同处理能力；

为了解决这些问题，做到像操作系统屏蔽硬件访问复杂性那样，屏蔽数据访问的复杂性，数据库应运而生。数据库通过不同的数据模型，设计出不同的数据结构，通过使用诸如表、视图、访问控制、日志等技术在一定程度上解决了文件系统存在的问题^[13]。

数据库除了可以解决这些问题，自身也包含许多实用的特性。

2.1.1 事务 (Transaction)

事务是指一个或多个数据库操作（如插入、更新、删除等）的逻辑单元，是数据库中数据一致性和完整性的保证。在一个事务中，所有操作要么全部执行成功，要么全部失败回滚，不会出现部分操作成功、部分操作失败的情况^[14]。

事务必须具备以下四个属性，也称为 ACID 属性：

1. 原子性 (Atomicity)：事务中的所有操作要么全部执行成功，要么全部回滚失败，不会出现部分操作成功的情况；
2. 一致性 (Consistency)：事务执行前后，数据必须满足一定的约束条件，如主键唯一性、外键关联等，简单来说，就是数据库随着状态的转移，需要始终保证其正确性；
3. 隔离性 (Isolation)：并发访问数据库时，事务之间是相互隔离的，一个事务执行过程中对其他事务不会产生影响；
4. 持久性 (Durability)：事务执行成功后，对数据库的修改是永久性的，即使系统故障或者机器崩溃，也不会影响已提交的事务；

事务的存在可以有效地维护数据库数据的一致性和完整性，避免数据的冲突和丢失。

2.1.2 索引和缓存

数据库中往往都会包含索引和缓存结构，这两个结构是提高数据库查询速度和性能的关键因素。索引类似于图书馆中的书目索引，在数据库中可以通过关键字快速定位到需要查询的数据。数据库索引可以分为多种类型，例如 B 树索引、哈希索引、全文索引等。其中，B 树索引是最常用的一种索引类型，它可以对关键字进行排序，并且支持范围查询。索引可以加速数据库的查询操作，但是也会增加数据的存储空间和维护成本^[15]。

缓存结构通常位于内存中，用来缓存数据库中的数据和索引等重要信息。缓存可以避免频繁的磁盘读写操作，减少磁盘 I/O 操作的开销。在数据库系统中，缓存通常由多级缓存组成，包括文件系统缓存和数据库缓存等多种类型的缓存。一些数据库也会直接绕过操作系统提供的缓存，直接在数据库系统中维护自己的缓存结构^[9]。如何保持缓存数据的一致性、如何正确清理缓存等是缓存结构的主要任务。

2.1.3 并发

文件系统中并不提供专门的并发控制机制，对文件的并发访问由操作系统来进行控制，不仅并发粒度大，而且难以保证数据的一致性。数据库往往具备更细的并发粒度和更强的并发控制能力。常见的并发粒度有数据行、数据表、数据页、数据库等，通过支持不同级别的并发力度，应用程序可以大大提高其并行效率。常见的并发控制策略有锁，版本控制，事务等^[16]。

2.2 Linux 内核与文件系统

Linux 内核与文件系统密不可分，文件系统是内核的一个重要组成部分。Linux 内核中实现了各种文件系统的支持，例如 EXT4、XFS、Btrfs、NTFS 等。文件系统的主要作用是管理文件和目录，提供文件的读写、创建、删除等操作，以及对文件的安全保护和权限控制^[17]。

Linux 内核中实现了通用的 VFS（Virtual File System，虚拟文件系统）层^[18]，所有文件系统都要实现 VFS 接口，以便于内核能够统一管理和访问各种不同类型的文件系统。VFS 层提供了一系列的文件系统操作函数，如打开、关闭、读写文件等，这些操作函数可以被上层应用程序和系统调用使用。在 VFS 层之下，每个具体的文件系统都有自己的实现，根据具体的文件系统类型提供相应的文件操作接口。

vfs 定义了一套统一的数据结构^[19]，底层的文件系统通过这些数据结构支持 vfs，其主要的结构如下：

- **SuperBlock**：超级块存储文件系统的元数据，包括文件系统类型，名称，挂载点，这些信息用于操作系统正确识别文件系统，其还保存文件系统的使用情况，磁盘空间剩余量；
- **Dentry**：用于表示文件系统树中的一个目录项，其记录了文件或目录在文件系统树的位置，通过遍历父目录，可以得到文件或目录的绝对路径。同时，dentry 还缓存最近使用的子目录项，管理文件系统的锁，并负责完成文件系统的挂载；
- **Inode**：用于表示文件系统中的文件。每个文件在文件系统中都有一个唯一的 Inode 结构体与之对应。其记录了文件在磁盘上的属性和元信息，是磁盘文件在内存中的映像；

- File: File 是用来表示打开的文件的数据结构，其包含了文件的访问模式、当前读写位置、对应的 Inode 等信息。每当用户打开一个文件时，内核就会为该文件创建一个 File 结构体，并将其作为文件句柄返回给用户程序。用户程序可以使用该文件句柄对文件进行读写、关闭等操作；

本文实现的文件系统 DBFS 想要接入到 linux 内核当中，就需要支持上述提到的数据结构和方法。

2.3 数据库文件系统实现技术与方法

有关数据库文件系统的研究集中在 2006 年 windows 提出 winfs 之际^[20]，大多数的数据库文件系统实现方案是在数据库之上封装一个文件系统的接口层，使得用户访问数据库时按照使用普通文件系统一样方便，这种方案主要用于远程服务器上，这种方案的好处是降低用户使用数据库的心智负担，但其并没有从本质上使用数据库来改进文件系统。另外一些流行的方案是从数据库中借鉴相关设计思路，并应用在文件系统的实现当中，这种方案一定程度上获得了数据库的好处，但仍然不够彻底，而且需要在文件系统实现数据库中已经具备且实现正确的复杂算法，引入了不必要的工作。一种能最大限度利用数据库的文件系统实施方案是，直接将数据库作为数据引擎，并在其上构建文件系统^{[21][22][23]}。

具体而言，这种方案需要一个功能强大的数据库，并且这个数据库的架构最好是类似于 sqlite 的单机数据库，因为诸如 MySQL 或者 Sqlserver 这种 C/S 架构的数据库，是无法将其移植到 linux 这种宏内核架构当中的。有了数据库之后，可以按照以下步骤来完成数据库文件系统 (DBFS)：

1. 因为数据库一般位于用户态，依赖操作系统提供的系统调用，因此第一步就是分析数据库对操作系统的依赖，并将依赖最小化；
2. 第二步，将数据库的接口依赖转换为内核函数的依赖，这一步尤为重要，因为数据库一般会以来操作系统提供的文件系统接口，但是此时数据库作为引擎需要直接管理底层的存储设备，因此需要考虑如何将对文件的操作转换为对底层设备的操作；
3. 第三步，在将数据库从用户态移植到内核中之后，此时可以按照数据库的提供的接口和数据结构来设计文件系统，这包含了使用数据库结构表达文件系统的

目录结构，存储文件元数据与实际数据，充分利用数据库提供的数据结构和算法有助于提升文件系统实现的性能；

4. 第四步，适配 linux 的 VFS，使得 DBFS 可以与其他文件系统一起由 vfs 结构统一管理；
5. 第五步，测试 DBFS 的正确性和性能；

这些是完成 DBFS 所需要的必要步骤，但直接在内核实现和测试文件系统可能存在一定的困难，一种可行的方案是在用户态实现 DBFS，使用普通文件模拟存储设备并使用用户态的测试工具集对其进行测试，在经过检验之后再将其移入内核。

2.4 编程语言

本文所包含的所有项目均使用 rust 实现。在涉及到操作系统和文件系统这样的低级别的任务时，往往多数人选择使用 c/c++ 来进行实现，而现在有了另一个选择，Rust^[24]是一个非常优秀的编程语言，其相比 c 语言来说，有许多优势：

1. 内存安全性^[25]：在编写操作系统或文件系统时这种底层代码时，一个常见的问题是内存泄漏、空指针引用等，这些问题在 Rust 中是不可能的或者很少发生的，因为 Rust 有强大的编译时借用检查和内存管理机制；
2. 零成本抽象：Rust 具有零成本抽象，这意味着我们可以在 Rust 中使用高级语言特性，同时不会增加额外的运行时开销。比如我们可以使用 Rust 的 trait 和泛型来创建高效的抽象数据类型，这可以使项目的代码更容易阅读和维护；
3. 性能：Rust 被设计为一种高性能的语言。在操作系统和文件系统等场景下，性能是一个非常关键的因素。Rust 通过使用内存安全性和零成本抽象等技术，可以在不牺牲性能的前提下提高开发效率；
4. 社区支持：Rust 拥有一个强大的开源社区，提供了许多有用的工具和库，这些工具和库可以帮助我们更轻松地构建操作系统和文件系统；

目前 rust 已经进入 linux 内核当中^[26]，并且可以使用 rust 来实现内核模块。本文选择 rust，也是因为未来 linux 社区对 rust 的支持进一步增强，那么使用 rust 实现的 DBFS 也将有望移植到 linux 内核当中。

2.5 本章小结

在这一章，本文介绍了数据库、文件系统的重要概念，并简述了数据库文件系统的实现方法以及本项目使用的编程语言，这为后面的 DBFS 具体设计奠定了知识基础。

第3章 DBFS 设计与实现

本章介绍了数据库文件系统 (DBFS) 的详细设计。在 3.1 节, 描述了 DBFS 项目的整体结构; 在 3.2 节, 描述了本文选择的数据库 jammdb 的数据结构和使用方法; 在 3.3 节中, 详细描述了 DBFS 中的接口设计和核心数据结构。在 3.4 节, 详细介绍了如何将数据库的数据结构对应到基于 Inode 的文件系统设计中, 说明如何保存文件的元数据和目录结构; 在 3.5 节, 介绍了使用 key-value 键值对存储文件数据的方法; 在 3.6 节, 介绍了如何将位于内核当中的数据库接口导出给用户使用。

3.1 DBFS 的整体结构

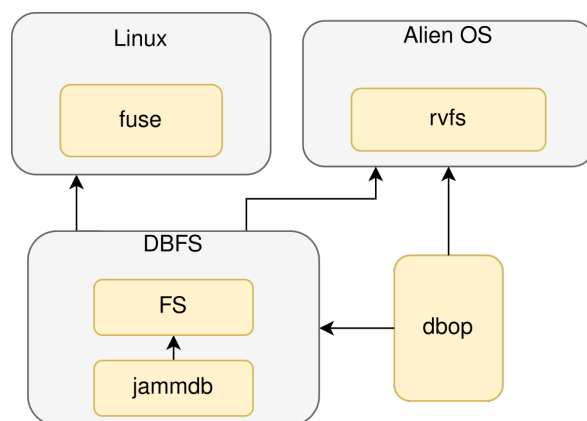


图 3-1 DBFS 整体结构

如图3-1所示, 整个 DBFS 被设计成一个与 OS 无关的模块, 而内部又由两个独立的模块构成, 分别是数据库和文件系统实现。本文的文件系统构建在一个键值对数据库之上, 因此需要选择一个符合要求的数据库, 本文选择了 jammdb, 选择的详细原因在 3.2 节描述。要使用这个数据库, 需要对数据库的依赖进行分析, 并对数据库做一定量的改造工作, 从而可以使其具备模块化特性和可移植性。数据库模块提供了基本键值对的插入、删除、查询操作。文件系统模块与传统的文件系统在功能上是类似的, 在这个模块中, 需要定义合适的数据结构和直观的接口, 合适的数据结构便于用户获取以及数据库存储, 直观的接口将有助于 DBFS 的移植和适配。文件系统模块需要依靠数据库模块提供的功能, 将定义好的数据结构通过数据库提供

的接口保存到数据库中或者从数据库中查询。

DBFS 作为一个独立的模块，可以成为一个用户态文件系统，也可以成为内核态文件系统。因此本文将 DBFS 接入了 linux 系统的 fuse 模块，同时将其移植到了本文实现的一个简单操作系统内核 Alien OS 中。为了将数据库的能力最大化，本文尝试将数据库的接口导出到用户态，dbop 负责定义和抽象数据库的接口，并被 DBFS 与 Alien OS 用来处理用户操作。

3.2 数据库结构的分析

jamddb 是一个嵌入式、单文件的 key-value 数据库，其提供 ACID 特性，支持多个并发读取和单个写入。所有的数据被组织成一棵 B+ 树，随机和顺序读取速度很快。其对文件的操作基于内存映射。选择这个数据库作为 dbfs 实现的原因是其结构比较简单，因为复杂的数据库不仅难以移植到裸机平台，要将其放到内核态需要大量的工作，但简单带来的一个坏处就是数据库的功能不够强大，并且数据库本身没有对磁盘设备作出相应的优化，这可能会导致最终的 DBFS 性能不能达到最好状态。

数据库的数据结构如图3-2所示：

数据库的内部基于桶 bucket 实现。如图所示，该数据库的基本结构由一个个处于全局空间的 bucket 组成，bucket 可以存储普通的 key-value 数据，这里 key 和 value 都是 [u8] 数组，同时也可以存储嵌套的 bucket 数据结构。一个 bucket 是由一棵 B+ 树构成，b+ 树将大小为 4k 或者其它大小的页面组织起来存储数据，这里的页面与传统文件系统的磁盘块类似，只是因为数据库使用内存映射而将存储结构描述为页。

数据库使用 mmap 系统调用来实现其缓存结构和事务特性，所有的只读操作发生在内存映射区域，当发生写操作时，数据库会及时刷新磁盘并同步更新内存映射。

3.3 DBFS 的接口设计与核心结构

图3-3显示了 DBFS 的接口设计。自下而上，DBFS 由各层接口连接起来，且每个层都是一个独立的模块，可以被其他项目所复用。各层的功能描述如下：

1. 最底层是最终数据的存储目标，在用户态，DBFS 可以将数据存储在一个普通文件中，在内核态，DBFS 与其他内核文件系统一样，将数据存储于块设备中；
2. 数据库层是存储算法的载体，其负责组织数据的存储，管理文件系统的所有信息，作为文件系统实现的引擎；

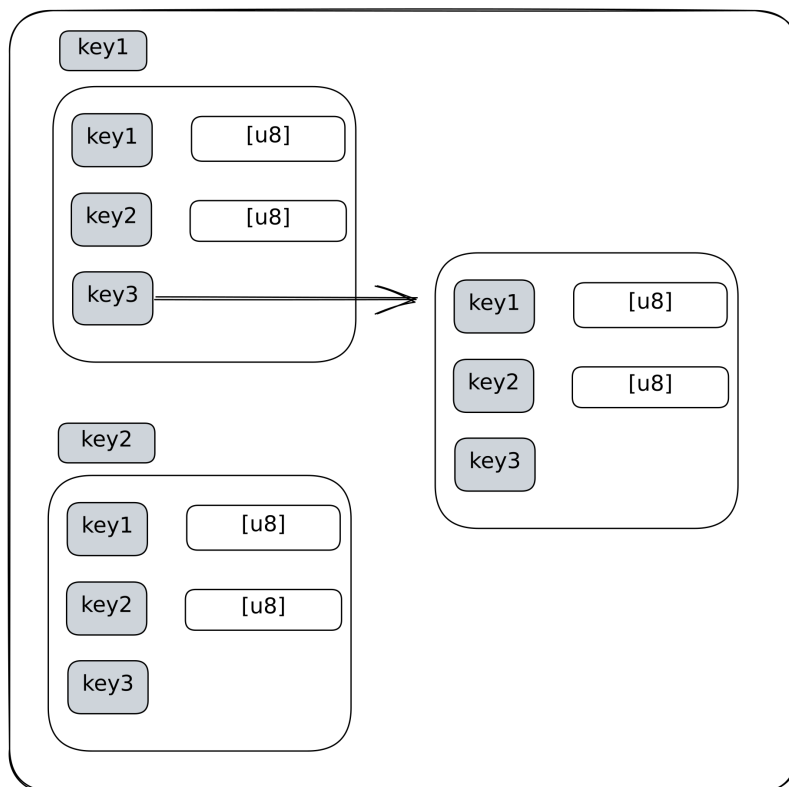


图 3-2 jammdb 结构

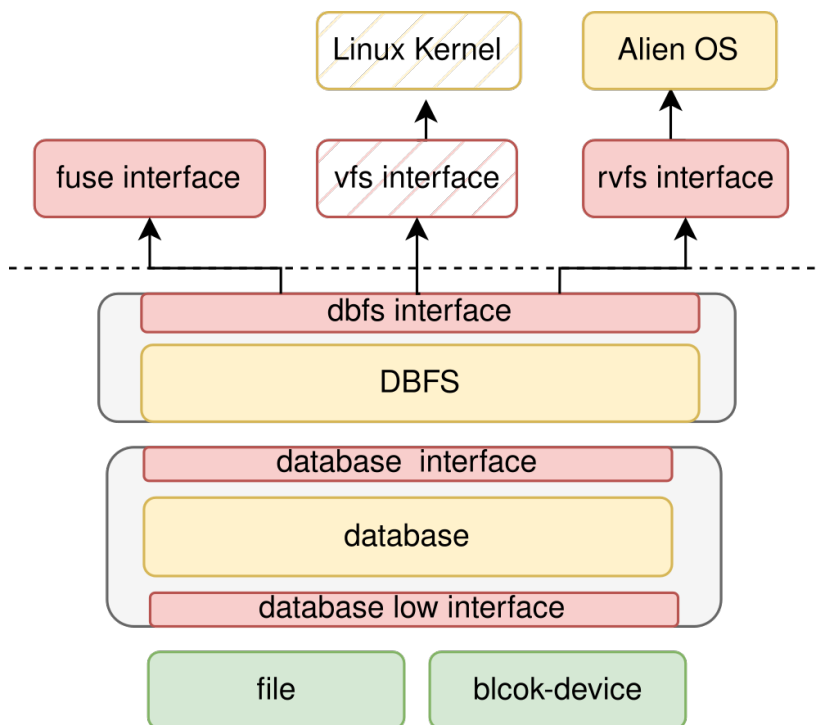


图 3-3 DBFS 层次结构

3. DBFS 层是文件系统实现层，文件系统的构建依靠数据库提供的功能，DBFS 提供了一层通用的接口，使得 DBFS 可以通过适配从而运行于用户态和内核态；
4. 最上层是 DBFS 最终的表现形式，如果将 DBFS 用在用户态，可以通过 DBFS 的通用接口适配 fuse 提供的接口，如果将 DBFS 移植到内核态，那么可以接入内核的 VFS 接口；

对于数据库来说，其原来的设计是作为一个用户态程序供用户使用，因此其依赖操作系统提供的功能 (mmap/File), DBFS 的最终目标是移植到内核当中，在内核中并不能直接使用这些函数，为此，本文需要修改数据库底层的接口，通过 rust 的类型系统将数据库对 OS 的依赖统一成独立的接口 (database low interface)，使得在使用数据库时，可以自定义底层接口，通过为文件或块设备实现对应的接口，数据库可以在用户态或者内核态中运行。

数据库本身提供接口 (database interface) 供用户使用，对于 jammdb，常用的接口是插入/删除一条键值对，插入/删除一个 bucket，还包含其它一些遍历键值对的接口。文件系统在这一系列接口之上实现。在参考了 VFS 主要接口和 Fuse 的接口后，本文在 DBFS 中为所有的文件系统操作提供了一个抽象层，在这个抽象层中，每一个函数即可以接收来自 VFS 的调用，也可以接受来自 Fuse 的调用。例如对于 read/write 两个操作，DBFS 提供的抽象接口形式如下所示：

```
1 pub fn dbfs_common_read(number: usize, buf: &mut [u8], offset: u64) ->
    DbfsResult<usize>
2 pub fn dbfs_common_write(number: usize, buf: &[u8], offset: u64) -> DbfsResult<
    usize>
```

代码 3.1: DBFS 接口

对于如何将通用接口适配到用户态和内核态，在第四章有详细的描述。

在 DBFS 这个模块中，其主要的数据结构图3-4所示，其核心是数据库实体 DB。在 DBFS 的初始化阶段，用户态的 fuse 或者内核的文件系统初始化函数会创建一个数据库实体，然后将此实体初始化位于 DBFS 的全局数据结构。初始化完成后，DBFS 将会完成之后针对文件的所有操作。在 DBFS 项目中，包含了用户态的 fuse 实现，因此用户可以直接在这个项目中完成用户态文件系统的挂载并在 linux 系统上完成所有文件系统相关的行为。对于 DBFS 的内核实现，则需要针对操作系统进行移植。本

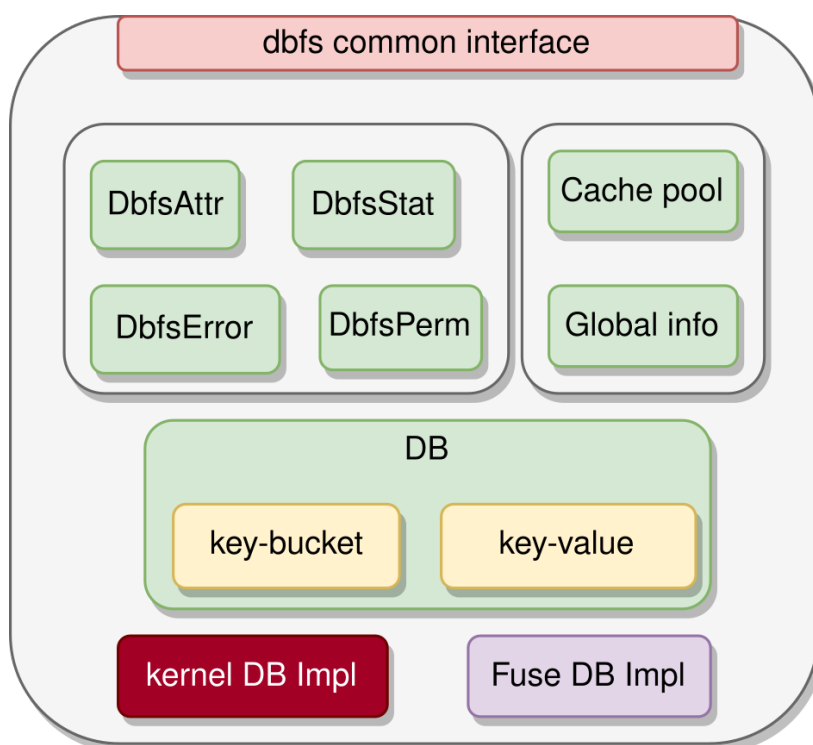


图 3-4 DBFS 核心结构

文在笔者自己实现的简单类 linux OS 中完成了这个移植。DBFS 内部包含了一系列数据结构，对于 DbfsAttr、DbfsStat、DbfsError、DbfsPerm 这类结构，其作用主要是完成通用接口与上层适配接口的转换，因为来自 VFS 或者 Fuse 的适配接口的需求不同，因此这些数据结构基本涵盖了两者的数据结构的要求。对于 Cache pool、Global info 这类接口，其主要作用一是缓存 DBFS 的一些信息，从而加速那些频繁发生的请求，比如一个经常会发生的请求是 readdir。作用二是避免一些不必要的内存分配开销，对于 Fuse 的实现，可能会频繁向操作系统申请和释放内存，加入一个局部的缓存分配器可以带来更好的局部性。

3.4 元信息管理与目录树构建

图3-5是使用 jammdb 数据库的数据结构来构建文件系统的设计图。这种设计主要是为了满足 linux 中 VFS 的路径解析算法，对于一个路径/d1/dd1/f1 来说，VFS 会依次解析/、d1、dd1、f1，即从根目录下递归地查找每一个路径分量，直到文件不存在或查找到文件。

根据设计图，本文将文件或者目录都使用 bucket 这个数据结构统一表示，这些 bucket 位于数据库的全局空间中而不是嵌套创建的，位于全局空间的这些 bucket 在

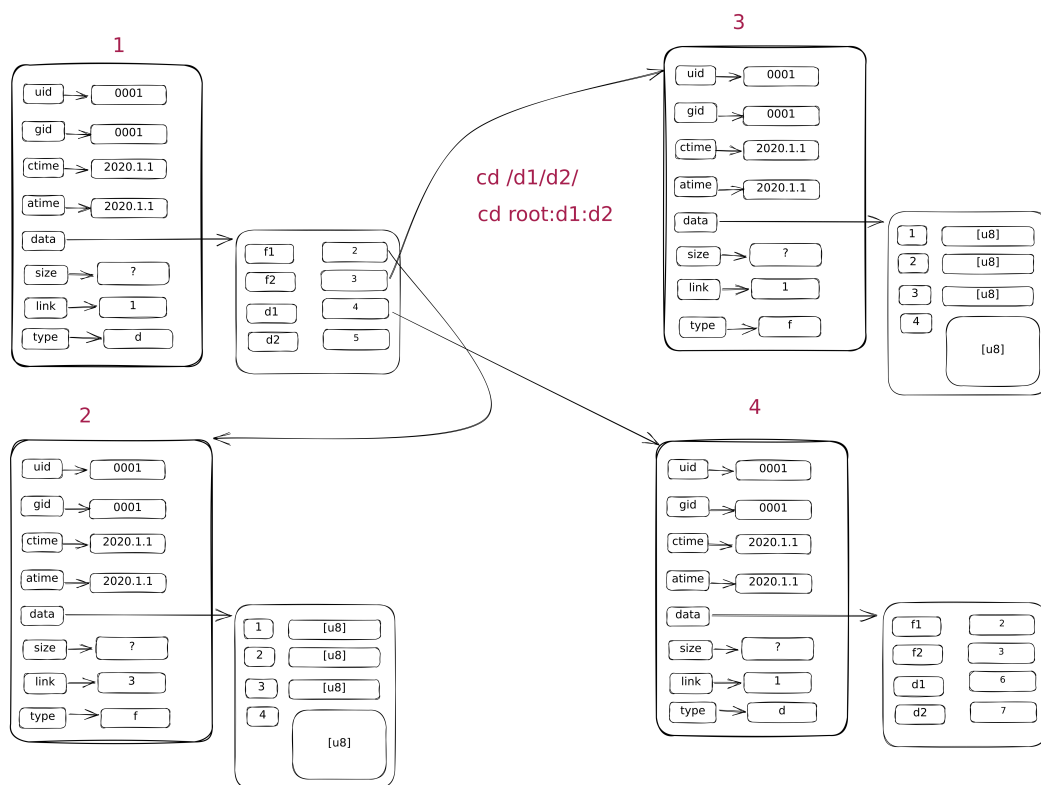


图 3-5 DBFS 元数据与目录树设计

创建时其 key 是一个只会递增的 64 位大小的数，这可以保证这些 bucket 在数据库中的唯一性。文件/目录的 bucket 的编号是唯一的，就像传统文件系统中的 inode number 一样。嵌套的 bucket 在这个设计中不被使用，如果使用嵌套的 bucket 来表示文件的话，这些文件会缺乏唯一的标识符，当 VFS 在进行路径解析时，将无法进行正确的查找，同时，由于缺少唯一标识，文件系统内部也无法有效地缓存文件的信息。

全局空间中除了文件和目录之外，还有一个额外的 bucket：超级块结构，超级块结构中只存储了少量有关磁盘和文件系统的信息：

表 3-1 Superblk

字段	含义
continue_number	64 位大小递增的数，用于唯一标识文件
magic	魔数，用于检验 DBFS
blk_size	块大小，与传统的块大小不同，下文将会介绍
disk_size	磁盘大小

当 DBFS 在挂载时，初始化函数将会从块设备中读取超级块的信息，在完成校验后会将 `continue_number` 初始到一个全局变量中，在后续创建文件或者目录时直接读取全局变量并进行自增操作。当操作系统调用刷新超级块操作或进行文件系统卸载时，这个全局变量会被写回到磁盘的超级块中。

在表示文件或目录的 `bucket` 中保存了其全部的元信息：

表 3-2 Bucket 信息

字段	含义
<code>gid</code>	文件所属用户 id
<code>uid</code>	文件所属用户组 id
<code>mode</code>	文件模式，包含权限和文件类型
<code>size</code>	文件大小，对于目录来说记录的是文件数量
<code>ctime</code>	文件最后一次元数据发生修改时间
<code>mtime</code>	文件内容最后一次修改时间
<code>atime</code>	文件最后一次访问时间
<code>hard_links</code>	硬链接计数
<code>blk_size</code>	块大小，与超级块中的一致

这些元数据可以满足绝大多数的文件操作，在创建一个文件或者目录时，将会有一个 `bucket` 被创建，并初始化这些字段信息，反之，当文件或目录被删除时，其对应的 `bucket` 被删除，所有元信息也会被删除。除此之外，DBFS 还支持文件系统的扩展属性，扩展属性（Extended Attributes）是一种可选的文件系统功能，用于在文件系统上为文件和目录附加元数据。扩展属性为内核提供了一种通用的、可扩展的元数据存储机制，可以支持许多不同的功能，例如访问控制、安全策略、元数据存储等。DBFS 没有专门为此开辟新的存储方式，而将其与普通的元数据一致对待，这些扩展属性被动态地添加和修改，并且对于扩展属性 DBFS 并不限制其键值对的大小，因为 DBFS 本身就是使用键值对来存储这些内容，这可以大大增强文件存储信息的能力。

在表示目录的 `bucket` 中，需要保存目录中的文件和子目录信息从而可以构建目录树结构，本文存储的方式如下：

表 3-3 目录存储方式

key	value	含义
data: name1	111	name1 文件在全局空间的 bucket 标识为 111
data: name2	222	name2 文件在全局空间的 bucket 标识为 222

目录将存储的子目录和文件组织在 key 为 data:name, 键为其在全局空间的 bucket 标识。各级目录通过一个键值对进行关联，从而模拟出一棵目录树。

3.5 文件数据存储

文件与目录一样都需要存储数据，只不过文件中存储的是来自用户的数据，与目录一样，本文也使用键值对来存储这些数据，并且这些键值对和那些元数据键值对一起位于同一个 bucket 当中，因为一个 bucket 由一个 B+ 树组织的页面构成，因此一个 bucket 至少占据了一个页大小的磁盘区域，将这些数据放在一起，可以保证在文件较小时，所有数据都位于同一个页面上，这可以充分利用磁盘空间并加速文件的读取。本文对普通文件的存储方式如下所示：

表 3-4 文件数据存储方式

key	value	含义
data: 0	[u8;blk_size]	第一块数据
data: 1	[u8;blk_size]	第二块数据
data: 2	[u8;blk_size]	第三块数据

对于数据库来说，其对 value 的大小没有限制，一种直观思路是直接把文件数据保存在一个键值对中，但数据库一般不会提供原地修改数据的功能，因此当文件数据发生修改时，就不得不对这条键值对进行读取-修改-插入三个动作，这对于大文件读写来说效率是不可接受的。本文借鉴了传统文件系统思路，将数据分块进行保存，在文件被修改时，只需要找到被修改数据所在的区间，然后针对一条键值对进行修改即可。同时，这些块大小可以进行配置，本文提供了 512B、1k、2k、4k、8k 大小的块大小供用户选择。

对于符号链接文件，其只保存了一个路径信息，因此其只包含一个数据字段：

表 3-5 软链接数据存储方式

key	value	含义
data	path	软链接路径信息

3.6 数据库接口导出

DBFS 具有了数据库的典型特征并被用户使用，但是只提供文件系统的功能却不能充分利用数据库。在具备文件系统功能的基础上，本文尝试将数据库本身的接口也提供给用户使用，用户除了按照正常使用文件的方式使用 DBFS，还可以直接使用数据库，并且此时使用数据库没有了文件系统设计中的限制，用户可以充分使用数据库的能力。

为了将数据库的接口导出到用户态，需要权衡性能和便捷程度。这里列举了数据库最主要的接口：

```
1 let tx = db.tx()
2 let bucket = tx.get_bucket()
3 tx.delete_bucket()
4 tx.get_bucket()
5 tx.create_bucket()
6 bucket.delete_bucket()
7 bucket.get_bucket()
8 bucket.get_kv()
9 bucket.put()
10 bucket.delete()
11 bucket.create_bucket()
```

代码 3.2: DBFS 接口

导出数据库接口，意味着需要在内核增加一些系统调用，若将上面的接口一一对应一个系统调用，则需要增加十几个系统调用，这虽然可以方便用户调用但大大浪费了宝贵的系统调用资源。本文选择的方案是将操作批次化，在一个系统调用中完成用户需要的操作。

具体而言，本文将数据库的这些基本操作结构化，每一个操作对应一个枚举类型，枚举包含一个结构体，结构体包含了这个操作需要的参数，这里以添加键值对和删除键值对为例，其对应的结构为：

```
1 pub struct AddKeyOperate {
```

```
2     pub map: BTreeMap<String, Vec<u8>>,
3 }
4 pub struct DeleteKeyOperate {
5     pub keys: Vec<String>,
6 }
```

用户的 `delete_bucket/delete` 操作用 `DeleteKeyOperate` 结构体表述，并且可以删除多个键。同理对于添加键值对也是一样。

在结构化这些基本操作后，因为这些操作是独立的，用户需要完成一些复杂操作的情况下可能需要多次进行系统调用，因此本文引入了嵌套操作的思路，目前主要支持两种情况的嵌套操作，一种是添加一个 `bucket`，后续用户可能会往此 `bucket` 中添加键值对，一种是进入一个嵌套的 `bucket`。针对这种情况，在表示这两个操作的结构体中，引入了一个嵌套字段，其示意如下：

```
1 pub struct AddBucketOperate {
2     pub key:String,
3     pub other:Option<Box<OperateSet>>
4 }
5 pub struct StepIntoOperate {
6     pub key:String,
7     pub other:Option<Box<OperateSet>>
8 }
9 .....
10 pub enum Operate {
11     .....
12     AddBucket(AddBucketOperate),
13     StepInto(StepIntoOperate),
14 }
15 pub struct OperateSet {
16     pub operate: Vec<Operate>,
17 }
```

需要注意的是，本文只在导出数据库接口上面做了基本尝试，这些接口可以满足用户的绝大部分需求。对于更为复杂的需求可能存在一定的局限。

3.7 小结

本章介绍了 DBFS 的设计与实现，通过对数据库的具体分析以及对 `ext` 文件系统的参考，本文充分利用了数据库的核心数据结构完成了 DBFS 的设计，并为 DBFS

设计了一个自下而上通用的接口，这使得数据库和 DBFS 都具有很大的灵活性和通用性。

第 4 章 DBFS 的 fuse 实现与内核移植

在上一章中讨论了 DBFS 文件系统的核心设计思路，本章则给出了将 DBFS 中与 OS 无关的接口适配到位于用户态的 Fuse 接口方案，然后给出将 DBFS 移植到内核中的方案。4.1 节介绍了 fuse 相关的知识以及 DBFS 的 fuse 实现；4.2 节介绍了本文实现的一个简单类 linux 内核，描述了这个内核的主要功能和模块。本文没有直接选择 linux 内核的原因在于目前内核中 rust 的支持不够完善，数据库以及 DBFS 使用的数据结构在内核中可能仍未支持，因此笔者在原有工作的基础上，完善了一个运行在 riscv 平台的简单操作系统 Alien OS，Alien OS 保持了与 linux 内核大致相同的体系结构，有了将 DBFS 移植到此内核中的成功经验，未来移植到 linux 内核中会更加顺利，虽然可以在 Alien OS 自行编写测试程序测试 DBFS 的性能，但这种做法说服力不强，将 DBFS 接入 Fuse，可以在将 DBFS 挂载到 linux 系统中，使用标准的测试工具来对文件系统的性能做评估，并与其他文件系统做比对。

4.1 linux 用户态 DBFS-Fuse 实现

Fuse (Filesystem in Userspace) 是一个用户空间文件系统接口^[27]，它允许非特权用户在不修改操作系统内核的情况下创建自己的文件系统。Fuse 提供了一种通用的机制，用于将用户空间的代码与内核文件系统接口连接起来，从而实现自定义文件系统的开发。

Fuse 文件系统工作流程如下：

1. 应用程序调用标准库中的系统调用，例如 `open()`，`read()` 等；
2. 应用程序的请求传递到 Fuse 内核模块，该模块负责将请求路由到特定的 Fuse 文件系统实现；
3. Fuse 文件系统实现处理请求并执行相关的操作，例如读取或写入文件；
4. 文件系统操作的结果返回给 Fuse 内核模块；
5. 内核模块将结果返回给应用程序，仿佛这些操作是直接由内核处理的一样；

Fuse 的优点在于，它允许用户空间程序使用一种通用的 API 来实现自定义文件系统。这使得开发人员可以更轻松地开发和测试文件系统，而无需担心对内核进行

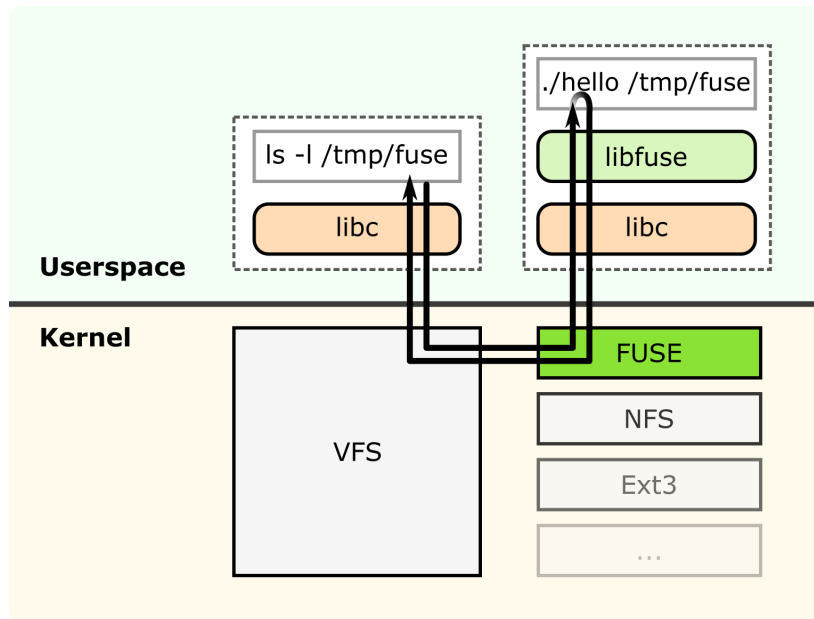


图 4-1 fuse 结构

修改。此外，Fuse 还提供了一些其他功能，例如访问远程文件系统，加密文件系统和网络文件系统等。Fuse 文件系统的缺点在于，由于所有文件系统操作都是通过用户空间代码执行的，因此对于某些高负载应用程序，可能会导致性能问题^[28]。

得益于用户空间的通用 API，Fuse 可以支持不同的编程语言来实现文件系统，其提供了一个名为 libfuse 的 C 库，该库包含了一组用于管理文件系统的数据结构和函数。大多数开发者会基于该库实现用户态文件系统，为了与整体的项目代码保持一致，本文并未使用该库，而是选择了一个使用 rust 实现的用户库 Fuser。两者在功能上没有差别，因此只要关注具体的文件系统实现即可。

Fuser 利用 rust 的类型系统，使得 fuse 的 API 可以更加直观和方便地被用户使用。为了支持 Fuse，需要实现一个定义好的接口。这些接口基本变形自内核中的 VFS，包含了一个文件系统主要的功能：

```

1 pub trait Filesystem {
2     fn init(&mut self, req: &Request<'_>, config: &mut KernelConfig) -> Result
      <(), c_int>
3     fn destroy(&mut self)
4     fn lookup(&mut self, _req: &Request<'_>, parent: u64, name: &OsStr, reply:
      ReplyEntry)
5     fn getattr(&mut self, _req: &Request<'_>, ino: u64, reply: ReplyAttr)
6     fn readlink(&mut self, _req: &Request<'_>, ino: u64, reply: ReplyData)
7     .....

```

前文提到，DBFS 提供了一个通用的接口层，只需从 Filesystem 这个 trait 定义的函数中获取到 DBFS 接口所需的参数，就可以直接将两者一一对应。

对于用户态文件系统来说，不能直接访问内核的存储设备，所以需要有一个虚拟的存储设备，这里使用了普通文件来进行模拟，通过实现前文提到的数据库的底层接口，就可以自下而上地打通整个项目结构。为了尽可能提高 DBFS 的性能，本文对其中的一些实现做了优化并实现了一些本来并不需要但是可以提升性能的接口，主要涉及的接口有 `readdirplus`、`copy_file_range`、`batch_forget` 等。

4.2 Alien OS

这是一个使用 rust 实现的简单类 linux 操作系统，其基于 qemu 模拟器并在未来运行于真实开发板上，支持 riscv64 位平台。这个简单的操作系统源自笔者的操作系统学习，其目的是探索 OS 模块化，整个内核由多个独立的模块构成。在 DBFS 移植到 linux 内核暂时处于不可行状态下，本文进一步完善了此内核并将其作为 DBFS 移植的目标。

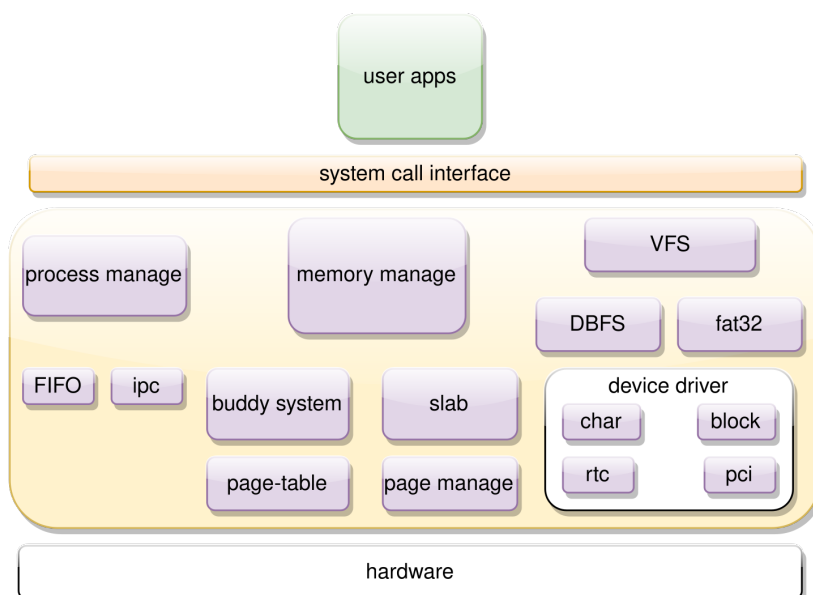


图 4-2 Alien OS 结构

整个系统的结构如图4-2所示，目前已经完成的功能包括内存管理，虚存管理，

外部设备，中断，进程管理，文件系统，虚拟文件系统等，已经支持数十个系统调用，同时支持 rust 编写的应用程序和 c 语言程序。在系统调用接口上，Alien OS 遵守 linux riscv syscall 调用规范。在各个模块内部，由一个个可重用的内部小模块构成，这些独立的模块有内存管理中的 Slab 分配器、伙伴系统，有虚拟内存管理的页帧管理器以及页表，有设备驱动里的串口设备，块设备，等等，这些独立的模块不仅可用于 Alien OS 中，也可以被社区中的其它 OS 使用。

4.3 VFS

在 Alien OS 中，有关 DBFS 最重要的部分是 VFS 与块设备。如果没有 vfs 的实现，那对不同文件系统的操作就需要分别进行判断和处理，并且 VFS 还起到缓存的作用，缺少缓存会导致用户存取和访问文件速度变慢，降低文件系统实现的性能。VFS 参考了 linux 的实现，在整体结构上与 linux 内核一样，其为不同的底层文件系统提供了统一的抽象，在其内部接入了一个内存文件系统用作初始挂在点、一个 fat32 文件系统以及本项目的 DBFS。

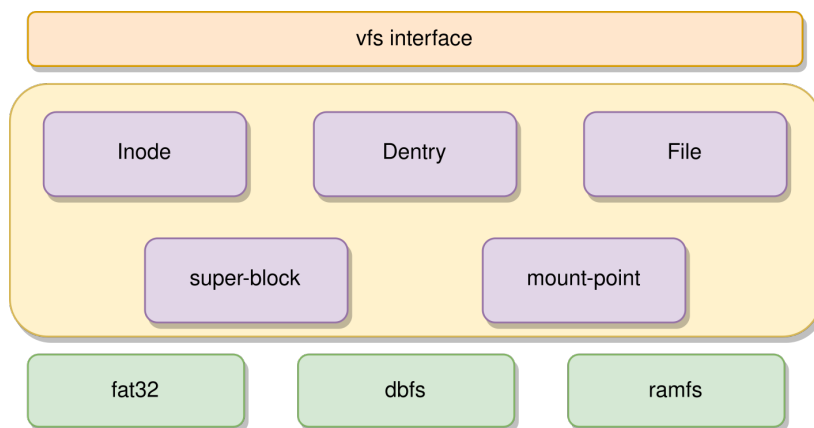


图 4-3 VFS 结构

设计上，其主要包含 5 个数据结构，Inode、File、Dentry、Superblock、Mountpoint 以及这些数据结构相关联的操作。这里给出了 Inode 数据结构和操作的定义，大部分字段都与 linux 的 VFS 相同，其它的结构也同样如此。

```
1 pub struct Inode {  
2     /// 文件节点编号--文件系统中唯一标识符  
3     pub number: usize,
```

```
4    /// 设备描述符
5    pub dev_desc: u32,
6    /// 索引节点操作
7    pub inode_ops: InodeOps,
8    /// 文件操作
9    pub file_ops: FileOps,
10   /// 块设备文件
11   pub blk_dev: Option<Arc<dyn Device>>,
12   /// 块大小
13   pub blk_size: u32,
14   /// 索引节点模式
15   pub mode: InodeMode,
16   /// 超级块引用
17   pub super_blk: Weak<SuperBlock>,
18   pub inner: Mutex<InodeInner>,
19 }
20
21 pub struct InodeInner {
22     /// 硬链接数
23     pub hard_links: u32,
24     /// 状态
25     pub flags: InodeFlags,
26     /// 用户id
27     pub uid: u32,
28     /// 组id
29     pub gid: u32,
30     /// 文件大小
31     pub file_size: usize,
32     /// private data
33     pub data: Option<Box<dyn DataOps>>,
34     pub special_data: Option<SpecialData>,
35 }

```

```
1 pub struct InodeOps {
2     pub follow_link: fn(dentry: Arc<DirEntry>, lookup_data: &mut LookUpData)
3     pub readlink: fn(dentry: Arc<DirEntry>, buf: &mut [u8])
4     pub lookup: fn(dir: Arc<Inode>, dentry: Arc<DirEntry>)
5     pub create: fn(dir: Arc<Inode>, dentry: Arc<DirEntry>, mode: FileMode)
6     pub mkdir: fn(dir: Arc<Inode>, dentry: Arc<DirEntry>, mode: FileMode)
7     pub rmdir: fn(dir: Arc<Inode>, dentry: Arc<DirEntry>)
```

```

8     pub link:
9         fn(old_dentry: Arc<DirEntry>, dir: Arc<Inode>, new_dentry: Arc<DirEntry
10         >)
11     pub unlink: fn(dir: Arc<Inode>, dentry: Arc<DirEntry>)
12     pub truncate: fn(inode: Arc<Inode>)
13     pub get_attr: fn(dentry: Arc<DirEntry>, key: &str, val: &mut [u8])
14     pub set_attr: fn(dentry: Arc<DirEntry>, key: &str, val: &[u8])
15     pub remove_attr: fn(dentry: Arc<DirEntry>, key: &str)
16     pub list_attr: fn(dentry: Arc<DirEntry>, buf: &mut [u8])
17     pub symlink: fn(dir: Arc<Inode>, dentry: Arc<DirEntry>, target: &str)
18     pub rename: fn(
19         old_dir: Arc<Inode>,
20         old_dentry: Arc<DirEntry>,
21         new_dir: Arc<Inode>,
22         new_dentry: Arc<DirEntry>,
23     )

```

作为简化，目前 VFS 实现了 linux 中的大部分常用接口，包括诸如读写、链接、属性扩展、文件状态、重命名、截断等，剩余少部分接口在未来会添加到其中。

在上述数据结构的基础之上，VFS 同样也提供一层接口供操作系统使用，这层接口以如下的方式暴露给使用者：

```

1 pub fn vfs_read_file<T: ProcessFs>(file: Arc<File>, buf: &mut [u8], offset: u64,)
   -> StrResult<usize>
2 pub fn vfs_llseek(file: Arc<File>, whence: SeekFrom) -> StrResult<u64>

```

得益与 rust 提供的抽象能力，使用 rust 实现的 VFS 相比 C 语言的实现更加易用和直观。

4.4 DBFS 内核移植

根据上文中描述的 DBFS 接口设计和 DBFS 的 fuse 实现可知，要将 DBFS 移植到内核态中，即使用存储设备作为数据库的底层存储介质，需要为 jamddb 实现其定义的底层接口。这些接口主要包含文件、内存映射两部分，对于文件来说，其接口定义如下：

```

1 pub trait FileExt {
2     fn lock_exclusive(&self) -> IOResult<()>;
3     fn allocate(&mut self, new_size: u64) -> IOResult<()>;

```

```
4     fn unlock(&self) -> IOResult<()>;
5     fn metadata(&self) -> IOResult<MetaData>;
6     fn sync_all(&self) -> IOResult<()>;
7     fn size(&self) -> usize;
8     fn addr(&self) -> usize;
9 }
10 pub trait Seek {
11     fn seek(&mut self, pos: SeekFrom) -> Result<u64>;
12 }
13 pub trait Write {
14     fn write(&mut self, buf: &[u8]) -> Result<usize>;
15     fn flush(&mut self) -> Result<()>;
16 }
17 pub trait Read {
18     fn read(&mut self, buf: &mut [u8]) -> Result<usize>;
19 }
```

对于内存映射 `mmap`，其接口定义如下：

```
1 pub trait IndexByPageID {
2     fn index(&self, page_id: u64, page_size: usize) -> IOResult< &[u8]>;
3     fn len(&self) -> usize;
4 }
```

文件的接口的功能主要就是进行读写和刷新并获取文件的元数据。

数据库原有的实现中，直接使用 `mmap` 系统调用建立打开文件的只读内存映射，在后续数据库中的所有只读操作，都直接读取内存映射部分而不使用文件的读取。`mmap` 是 Linux 中用于将文件或设备映射到进程地址空间的系统调用，它将文件映射到进程的地址空间中，使得进程可以直接访问文件中的数据，而无需进行系统调用。通过 `mmap`，进程可以将一个文件映射到内存中，并且对内存所做的所有修改都会被直接写入到文件中，而无需进行额外的 I/O 操作。通常来说，`mmap` 系统调用需要操作系统支持内存页的换入换出及缺页处理，而这一般是针对一个进程进行处理。将数据库移到内核态，这个时候就不能再依靠 `mmap` 系统调用了。

如图4-4所示，在内核中，本文将块设备映射到一段连续高位的虚拟地址空间中，这段连续的虚拟地址空间即扮演了文件的角色，同时又满足了 `mmap` 的含义。直接从块设备中存取数据速度是缓慢的，将块设备映射到内存中还可以使得后续对块设备的读写直接在内存中进行加快速度，这段虚拟地址空间还起到了缓存的作用。

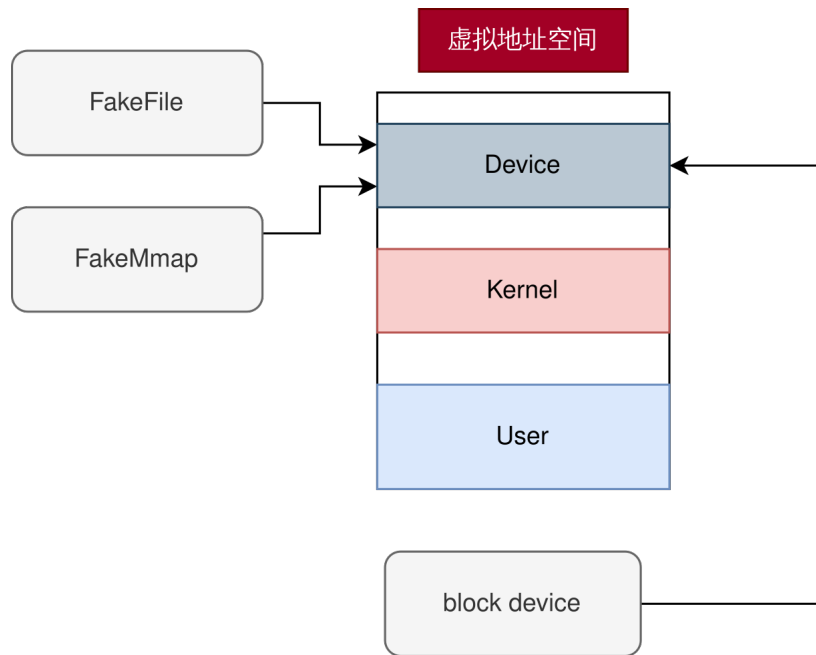


图 4-4 DBFS 内核移植

为了实现上述的这些接口,本文分别定义了两个数据结构 FakeFile 与 FakeMmap,其定义如下:

```

1 pub struct FakeFile {
2     offset: usize,
3     size: usize,
4 }
5 pub struct FakeMmap {
6     start: usize,
7     size: usize,
8 }

```

FakeFile 作为模拟块设备的虚拟文件,只记录了当前的偏移量和文件大小,其需要实现 File 相关的接口,对于 `alloc` 函数,其会在数据库增大文件大小时调用,而块设备的大小是固定的,因此内核只会在申请的大小超过块设备大小时报错而不做其它处理;对于 `lock_exclusive` 与 `unlock` 函数,因为只有一个块设备且位于内核中,不会发生用户态中多个进程读取同一文件的现象发生,因此这里也不需要处理;对于 `sync_all` 与 `flush` 函数,虚拟文件会将虚拟地址空间中的脏页刷写到块设备中。

FakeMmap 需要实现内存映射的接口,当数据库在进行 `mmap` 操作时,其调用底层的接口,而内核中这个接口实现不会做任何操作。当数据库读写位于内存映射的数据时,就会调用上述定义的内存映射接口 `index`,`index` 会根据读取的页编号和页

大小直接访问为块设备创建的虚拟地址空间。

这块虚拟的地址空间在 DBFS 初始化时创建并加入到页表中。之后对文件的访问会直接访问这片地址空间，从而触发缺页处理。当用户进行文件的读取时，自上而下发生的操作序列为：

1. 用户在用户态调用 `read/write` 函数进行文件的读取和写入；
2. OS 发生陷入，并处理用户的系统调用；
3. OS 调用 VFS 层接口路由到正确的文件系统中，这里假设使用了 DBFS；
4. VFS 调用 DBFS 的通用 `read/write` 接口；
5. DBFS 调用 `jammdb` 的 `put/get` 操作，获取数据对应的键值对；
6. `jammdb` 内部使用索引算法查找，最终调用底层的接口实现，这里就是模拟块设备的虚拟文件；
7. 虚拟文件直接访问映射的虚拟地址空间，查找数据块是否已经读入内存中，若已经读入，则不会发生缺页异常可以返回内存的内容或直接写入内存，若对应数据块没有被读入则触发缺页异常，先读入缓存，再按照缓存在内存的情况进行处理；

通过共享同一个虚拟地址空间，可以简化数据库底层接口的实现，而且此时并没有破坏数据库提供的事务特性。

4.5 性能优化

在初期测试 DBFS 的 `fuse` 实现的性能时，不管是大文件的读写性能还是元数据处理能力，DBFS 都与其他文件系统存在较大的差距，但是按照设计方案来说，其设计与 `ext` 系列的文件系统有相似的结构，理论上不应该存在如此大的性能差距，因此可以推断其内部仍然具有较大的改进空间，并且导致这些问题的一定是显而易见的一些设计缺陷。通过反复实验与测试，本文观察到了几个可以提升性能的地方并在最终测试前进行了改进。

4.5.1 flush+sync_all

在数据库中,每当一个写事务发生,根据jammdb的机制,会调用flush和sync_all来将文件的元数据以及缓存中的数据写回磁盘,并更新mmap中的只读缓存,由于缺乏写缓存且fuse位于用户态,这导致了非常大的性能开销,因此需要在这两个函数中作一定的优化。具体而言,在实现jammdb的底层File的接口时,并不直接将flush和sync_all映射到File的这两个接口。原来这两个接口的实现是这样的:

```
1 fn flush(&mut self) -> core2::io::Result<()> {
2     self.file
3         .flush()
4         .map_err(|_x| core2::io::Error::new(core2::io::ErrorKind::Other, "
        flush error"))
5 }
6 fn sync_all(&self) -> IOResult<()> {
7     self.file
8         .sync_all()
9         .map_err(|_x| core2::io::Error::new(core2::io::ErrorKind::Other, "
        sync_all error"))
10 }
```

对这两个接口的初步改进方案是直接将对文件的这两个调用忽略掉,因为操作系统内部会自己更新文件和内存映射中的数据。但这种改进方式存在破坏数据库事务特性的可能,因此更好的做法是将开启一个后台线程,异步地完成刷新操作。

4.5.2 固定文件大小

在原来的实现中,本文使用本机的文件模拟DBFS的镜像文件,但这个实现是按照数据库的申请而逐渐增大文件大小的,对于ext文件系统,一开始就分配了一个固定大小的镜像文件,因此在读写过程中并不会向系统再次申请文件,而对于juicefs来说,其本身不需要读取镜像文件,而是直接使用linux的文件接口。

在这个改进中,本文在创建文件时,会先像ext文件系统一样分配一个固定大小的文件,因为所有的性能测试的文件大小都在一个可预测的范围,因此整个过程中数据库虽然会调用增大文件的接口但本文的实现是不会进行分配的。同时,对于mmap系统调用,在数据库的原实现中,每一次增大文件都会重新进行映射,本文的改进已经固定了文件的大小,因此对这个调用也同时进行了修改,只需要在第一次进行映射时记录映射的数据地址,后面调用这个接口时,返回的仍然是第一次映射

的数据。

4.5.3 调整块大小

对于 DBFS 来说，块大小其实指的是在使用 key-value 键值对保存文件数据时做的优化手段，这在设计文档中已经详细说明。在原实现中，本文规定了这个块大小为 512 字节，但是在实验初期发现，其他几个文件系统使用的块大小都为 4kb 大小，在进行 fio 测试时，本文设定了每次读取的大小为 1MB，对于其他几个文件系统来说，每次只需要读 256 个块，但是对于 DBFS 来说就需要读取 2048 个键值对，而且这些键值每次都需要进行搜索，其他文件系统则会尝试分配在一个连续的空间，因此增大 DBFS 的块大小，理论上是可以增大吞吐量的。这里改进是增加了几个可选的块大小。

```
1 #[cfg(feature = "sli512")]
2 pub const SLICE_SIZE:usize = 512;
3 #[cfg(feature = "sli1k")]
4 pub const SLICE_SIZE:usize = 1024;
5 #[cfg(feature = "sli4k")]
6 pub const SLICE_SIZE:usize = 4096;
7 #[cfg(feature = "sli8k")]
8 pub const SLICE_SIZE:usize = 8192;
9 #[cfg(feature = "sli32k")]
10 pub const SLICE_SIZE:usize = 8192*4;
```

通过对这些块大小进行实验，本文最终发现 32k 是一个临界值，超过 32k 的块大小会导致性能开始下降。因为 32k 大小的块大小可能会导致当文件系统中存在大量小文件时造成空间的浪费，所以用户可以评估其需求在存储空间和性能之间作出选择。

4.6 小结

在本章中首先介绍了将 DBFS 接入到 linux 的 fuse 用户态文件系统的实现方案，然后介绍了一个使用 rust 实现的类 linux 操作系统以及其中与文件系统相关的 VFS 模块，最后介绍了将 DBFS 移植到此内核的方法。DBFS 的 fuse 实现可用于文件系统的标准测试，而 Alien OS 的 DBFS 移植可用于未来将其移植到 linux 内核的参考。

第5章 测试与分析

本章对 DBFS 的实现进行测试并对 DBFS 做了相关的改进，为了实验更具有说服力，所有的测试使用 DBFS 的 fuse 实现并使用 linux 的标准文件系统测试工具。5.1 节介绍了文件系统的主要测试指标和本文选择进行对比的文件系统相关知识；5.2 节介绍测试环境和条件；5.3 节介绍文件系统正确性测试；5.4 节介绍文件系统元数据操作性能测试；5.5 节介绍文件系统吞吐量测试；5.6 节介绍实际应用负载测试；5.7 节介绍 Alien OS 中与 FAT32 进行的测试。

5.1 测试指标与其它文件系统

文件系统性能测试可以使用多个指标来衡量，一些常见的文件系统测试指标^[29]如下：

- 延迟（Latency）：文件系统读取或写入数据所需的时间。延迟是衡量文件系统性能的重要指标，因为用户通常关心操作完成所需的时间；
- 吞吐量（Throughput）：文件系统在一定时间内读取或写入数据的速率。吞吐量通常用 MBps 或 GBps 表示；
- IOPS（每秒输入/输出操作数）：文件系统在一秒钟内处理的读写操作数。IOPS 通常是衡量闪存存储设备性能的重要指标；
- 并发性（Concurrency）：文件系统同时处理多个读写操作的能力。并发性是在高负载条件下测试文件系统性能的关键指标；
- 可靠性（Reliability）：文件系统出现故障或意外情况时的恢复能力。例如，当系统意外断电时，文件系统应该能够在重新启动后恢复数据；
- 一致性（Consistency）：文件系统保持数据一致性的能力。例如，当多个用户同时读取和写入文件时，文件系统应该能够正确处理数据并保持一致性；
- 安全性（Security）：文件系统保护数据不被非授权用户访问的能力。例如，文件系统应该支持文件权限和访问控制列表（ACL）；

测试指标的选择取决于文件系统的具体用途和性能需求^{[30][31]}。在选择测试指标时，应该考虑到测试环境、应用场景和用户需求。对于安全性测试，通常操作系统在 VFS 层就会完成大部分的权限检查，因此具体到实际的文件系统实现权限检查就只会占据一小部分。对于一致性测试，在基于数据库的文件系统实现中，数据库会提供一致性保证，因此也可以减少这部分的测试。在本文中，主要覆盖了吞吐量、IOPS、兼容性、并发几个测试指标。

为了与其他文件系统的性能有直观的比较，本文选取了 ext 系列文件系统 ext3 和 ext4。ext 这个系列的文件系统都具有 fuse 的客户端，因此可以与 DBFS 进行对比。这里简要概述了 ext 系列文件系统的相关知识。

ext2 是 Linux 中最早的文件系统之一，也是最简单的文件系统。它具有可靠性和稳定性，但不支持日志记录和热插拔。ext2 文件系统的优点是速度快，适合用于嵌入式系统和旧硬件设备。ext3 是在 ext2 基础上发展而来的文件系统，增加了日志记录功能，可以避免文件系统损坏。当系统异常关机时，ext3 会使用日志记录来恢复文件系统，保证数据的一致性。ext3 的日志功能对磁盘的驱动器读写头进行了优化，所以，文件系统的读写性能较之 Ext2 文件系统并来说，性能并没有降低。ext4 是在 ext3 基础上发展改进的文件系统，增加了一些新功能和性能改进。它支持更大的文件和分区，支持快速恢复和热插拔。此外，ext4 还采用了一些新的技术来提高文件系统性能，如延迟分配、多块分配和快速预读取。实验中，本文选择使用 ext3 与 ext4 两个主要版本进行测试。

5.2 测试环境和准备

机器信息：

- 8 Intel(R) Core(TM) i5-8265U CPU @ 1.60GHz
- 8GB memory
- Ubuntu 22.04.2 LTS

程序运行条件：

1.DBFS 使用 release 模式运行, mount 参数为

```
1 -o auto_unmount allow_other default_permissions rw async
```

2.ext3 使用 fuse2fs 工具进行挂载,其挂载参数与 DBFS 的相同。具体步骤为:

1. 使用 dd 生成 20GB 大小的文件;
2. 使用 mkfs 工具对文件进行格式化生成对应的文件系统;
3. 使用 fuse2fs 工具将文件系统挂载到任意一个空目录上;

5.3 pjdftest POSIX 兼容性测试

pjdftest 是一套简化版的文件系统 POSIX 兼容性测试套件,它可以工作在 FreeBSD, Solaris, Linux 上用于测试 UFS, ZFS, ext3, XFS and the NTFS-3G 等文件系统。目前 pjdftest 包含八千多个测试用例,基本涵盖了文件系统的接口。

在挂载 DBFS-fuse 后,可以在挂载目录下运行测试程序得到 DBFS 的测试结果。

5.3.1 结果说明

表5-1显示了测试结果。在 pjdftest 测试中,DBFS 通过了 92% 的测例,这说明 DBFS 的整体实现正确,并且符合 POSIX 语义。在各个单独的测设集合中,DBFS 全部通过了包括 link、mkdir、open、truncate 等在内的所有测试。DBFS 发生错误的位置主要集中在 rename 和 chown 的处理当中,rename 是文件系统中最为复杂的操作,在各个文件系统中都是代码量很多的部分,DBFS 实现并没有处理到位所有的细节,导致这部分出现了一部分错误,chown 是权限检查的主要函数,linux 中文件权限管理细节比较多,DBFS 在实现中简化和忽略了一些判断,从而导致这部分部分测例也未通过。其他测试集合中未通过的测例较少,这里推测是由于其它测试集合中也包含了 rename、chown 这些操作,同时 DBFS 中对错误返回值的处理可能没有按照 Posix 标准进行返回。总体而言,DBFS 的正确性处于一个较高的水平,与一些用户态文件系统相比,其对 POSIX 接口的兼容性具有更大的优势。

5.4 mdtest 元数据性能测试

mdtest 是一款针对服务器元数据处理能力的基准测试工具,可以用来模拟对文件或目录的 open/stat/close 操作,然后返回统计信息。其支持 MPI,可以用来协调大量客户端对服务器发起请求,mdtest 的主要参数如下:

表 5-1 pjdftest 测试结果

test-set	interface	pass/all	error/all	error
chflags	chflags(FreeBSD)	14/14	0	linux 下不工作
chmod	chmod/stat/symlink/chown	321/327	26/327	chmod 实现有误
chown	chown/chmod/stat	1280/1540	260/1540	chmod 实现有误
ftruncate	truncate/stat	88/89	1/89	Access 判断出错
granular	未知	7/7	0	linux 下不工作
link	link/unlink/mknod	359/359	0	无
mkdir	mkdir	118/118	0	无
mkfifo	mknod/link/unlink	120/120	0	无
mknod	mknod	186/186	0	无
open	open/chmod/unlink/symlink	328/328	0	无
posix_fallocate	fallocate	21/22	1/22	Access 判断错误
rename	rename/mkdir/	4458/4857	399/4857	错误返回值处理与逻辑错误
rmdir	rmdir	139/145	6/145	错误处理，权限检查
symlink	symlink	95/95	0	无
truncate	truncate	84/84	0	无
unlink	unlink/link	403/440	37/440	mknod 中的 socket, 错误处理
utimensat	utimens	121/122	1/122	权限检查
		7943/8674	731/8674	92%

- -b: 目录树的分支参数;
- -d: 指出测试运行的目录;
- -I: 每个树节点包含的项目;
- -z: 目录树的深度;

各个文件系统的测试命令为 `sudo mdtest -d path -b 6 -I 8 -z 3`。

图5-1显示了测试结果。在 `mdtest` 测试中，总体来说 DBFS 的性能与最好的 `ext3` 相比在某些操作上具有一定的优势。在 `rename` 操作上，这个优势甚至可以达到数十倍。在 `File Stat`、`Dir Stat` 两种查找操作上 DBFS 与 `ext3` 的没有较大的差距，这得益于 DBFS 中数据库快速的索引查找机制。在 `Tree creation`、`Tree removal` 这类比较复杂的操作上 DBFS 与 `ext3` 的存在一定的差距，这可以从 `File creation`、`Directory creation`

、Directory removal 等操作中得到原因，由于 DBFS 在这几个操作上本就比 ext3 慢了一个数量级，而 Tree creation 操作是这几个简单操作的组合，因此总体下来就会导致这样的差距。

在 ext3 和 ext4 的 fuse 实现中，为了提高性能，其中加入了许多缓存机制，其缓存了文件系统的大部分元信息，这可以使得对于文件信息和对目录信息的获取速度大幅度增加。而这些信息也可以让删除，重命名等操作直接在内存中完成。在 DBFS 的实现中，本文并没有为 Fuse 提供专门的缓存机制，因此每一次的查找、删除操作都会直接对文件进行操作，相比其 ext 的文件系统，DBFS 的元数据处理能力肯定会打折扣，但从图5-1中也可以看出，即使 DBFS 没有元数据缓存的加持，在许多操作上同样也能达到较好的性能。如果为 fuse 的实现加入缓存，那其与 ext 的性能差距将会进一步缩小。

5.5 fio 读写性能测试

fio 是一款基于命令行的磁盘 I/O 性能测试工具，可以测试各种不同类型的磁盘 I/O 工作负载，例如随机读写、顺序读写、混合读写等。fio 可以在 Linux、FreeBSD、macOS 等操作系统上运行，支持多线程、异步 I/O 和多种 I/O 引擎，具有高度的可定

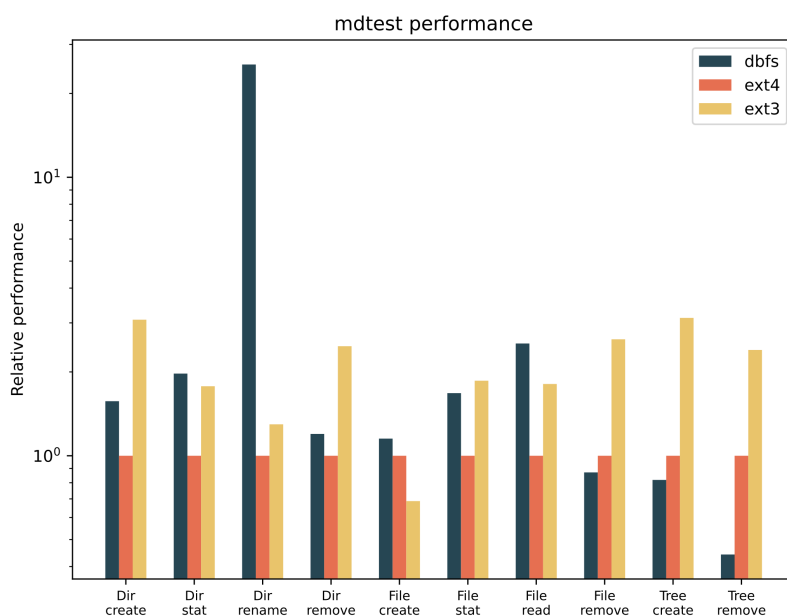


图 5-1 mdtest 结果

制性和可扩展性。

fio 的主要参数有：

- `-name`: 用户指定的测试名称，会影响测试文件名；
- `-directory`: 测试目录；
- `-ioengine`: 测试时下发 IO 的方式；通常用 `libaio` 即可；
- `-rw`: 常用的有 `read`, `write`, `randread`, `randwrite`, 分别代表顺序读写和随机读写；
- `-bs`: 每次 IO 的大小；
- `-size`: 每个线程的 IO 总大小；通常就等于测试文件的大小；
- `-numjobs`: 测试并发线程数；默认每个线程单独跑一个测试文件；
- `-direct`: 在打开文件时添加 `O_DIRECT` 标记位，不使用系统缓冲，可以使测试结果更稳定准确；

为了屏蔽操作系统缓存带来的影响，在进行读写吞吐量进行测试时，将读写的文件设置为内存容量的 2 倍。并且在测试读性能时，不能紧跟着写测试，因为写测试会填充操作系统的缓存，因此在写入完成之后，需要使用 `bash` 命令将操作系统缓存写回到磁盘中。fio 的测试包含了单线程和多线程两个测试，在多线程测试中，开启 4 个线程，每个线程读写 3g 大小的文件。每次读写的块大小设置为 1MB，设置 `direct=1` 忽略系统缓冲。

图5-2显示了测试结果。在顺序写中，`ext3` 的性能最好，几乎达到了原生读写的速度。而 `ext4` 的性能只是 `ext3` 的 25%，`DBFS` 的性能是 `EXT3` 的 90% 左右，是 `ext4` 的 3 倍，说明 `DBFS` 的写性能在一定程度上是可以追赶上 `ext` 系列文件系统的。在顺序读中，`ext3` 的读取速度仍然是最快的，而 `ext4` 的读取速度是其 89% 左右，对于 `DBFS` 来说，其读性能相较于两个系统都比较差，只达到了 `ext4` 的 15% 左右。在随机写测试中，`ext3` 与 `DBFS` 都保持了与顺序写差不多的性能，性能损失在 10% 以内。对于 `ext4`，其性能损失达到了 35% 左右。`DBFS` 的随机写性能是 `EXT4` 的 3 倍，是 `ext3` 的 60% 左右。在随机读测试中，`EXT3` 和 `EXT4` 都有较大程度的性能下降，但

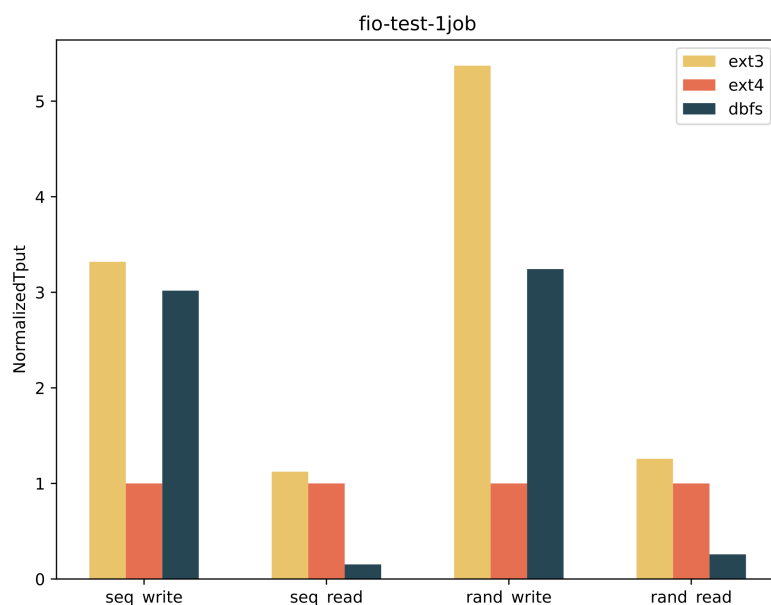


图 5-2 Fio 单线程测试

两者的差距并不是很大，ext4 是 ext3 的 80% 左右。对于 DBFS，其性能与顺序读有相同的性能数据。由于 ext3 和 ext4 的性能下降，反而让 DBFS 的性能超过了两者的 20%，但整体性能依然比较落后。

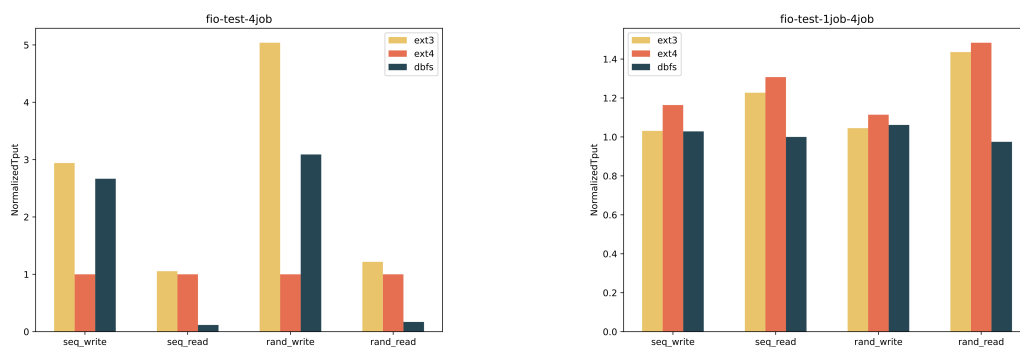


图 5-3 Fio 并发测试结果

图 5-3显示了并发读写的结果。在并发读写测试中，从图5-3右图可以看到，不管是对于顺序读写还是随机读写，三个文件系统都有一定的性能提升，在写测试中三者的性能提升在 10% 以内，在读测试中 ext 两者有显著的性能提升，甚至达到了单

线程下的 1.4 倍。对于 DBFS 来说，其读测试与单线程下的没有提升，其与 ext 的性能差距被放大，说明 DBFS 在并发控制方面的能力比较薄弱。

5.5.1 分析

在读写测试中可以看到，在写操作下 DBFS 是可以超过 ext4 的性能的，甚至与 ext3 在同一水平。而在读操作下 DBFS 的性能会急剧下降，以至于可能只有两者的 15%。造成这个性能差距的原因涉及到了诸多方面，其一，DBFS 的 fuse 实现本身就与 ext 的实现存在实现细节的差异，DBFS 对 fuse 没有做更多的优化，而 ext3 和 ext4 的 fuse 实现是有针对性的优化措施的，比如在进行数据读写时减少数据的拷贝，直接在内核和用户态传递数据，这在读操作时性能提升尤为明显，在 DBFS 中，一次读操作需要两次拷贝数据，一次从数据库中拷贝到申请的内存中，一次从申请的内存中传递到内核中，对于读 15GB 数据的测试来说，相当于 DBFS 需要读取 30GB 大小的数据；其二，在 DBFS 中，使用了键值对来存储文件数据，这导致这些数据可能会分散在不同的页面中，而且这些数据可能跨过多个页面，而在 ext 文件系统中，文件在存储时倾向于将这些数据存放在连续的块中，在进行读取操作时，ext 文件系统可以直接快速查找到文件的数据存储区域，而在 DBFS 中，每一次的查找都会数据库可能都会遍历存储的所有键值对，即使使用树结构可以加速查找过程，但频繁的查找相比只需要几次查找仍然带来了巨大的开销。同时，由于 ext 的数据存储在连续的块中，这可以减少缓存失效，而 DBFS，由于需要进行索引，因此需要频繁地进行缺页处理，而这些页面会在缓存中不断地切换，同样这也会造成性能下降，在写测试中，性能数据产生的波动应该来自于此；其三，在并发测试中，DBFS 的写性能提升很小，读性能几乎没有变化，在实现中，每一次写操作都会变成一个写事务，而数据库的写事务将会使得文件被加锁，由于数据库的加锁粒度过大，导致在并发情况下数据库的写操作变成了跟单线程一样的串行操作。对于读操作来说，按理来说读事务不没有对文件加锁，因此其性能应该有较大的提升，但实验中并没有发生，其原因因为时间有限的关系没有进行输入的分析，初步的推断应该与频繁的换页处理有关。

虽然 DBFS 在打文件的写性能测试中达到了与 ext3 相同的水平，但实验发现，DBFS 在写性能上仍然存在改进的空间，图5-4显示了重复写大文件的情况，在第一次写入大文件时，其性能确实与 ext3 位于同一水平，但当望这个大文件再次写入数

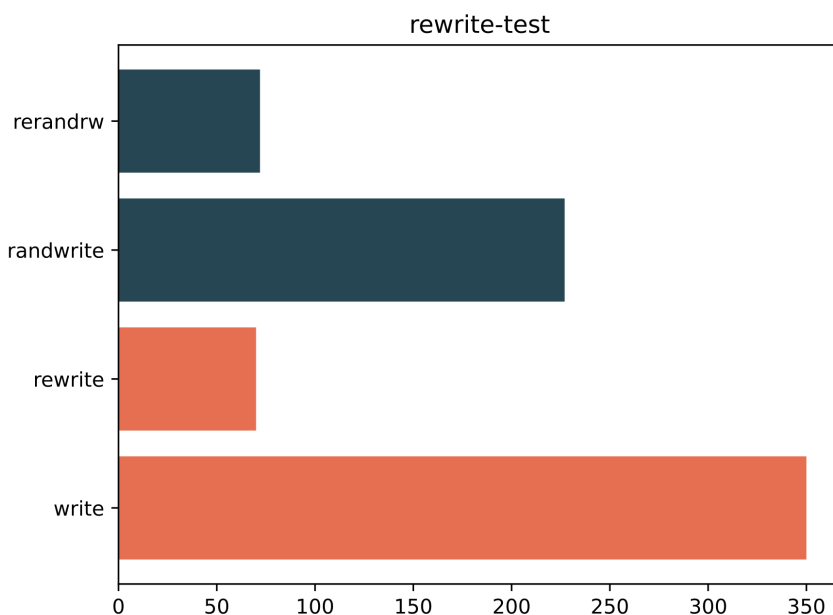


图 5-4 rewrite 测试

据时，其性能就会下降到第一次的 1/4 左右。造成这个现象的原因是来自数据库本身的机制，由于使用键值对进行存储数据，在第二次写数据时，需要覆盖第一次写的数据，相当于需要删除原来的一个键并插入一个新的键，而这些键值对存储在页面中，一个键的插入或删除会导致有 B+ 树组织的页面发生分裂或者合并，当这个操作发生频繁时，将会导致性能的快速下降。虽然现实场景中往一个大型文件中重复写入数据不常见，但这确实是一个需要改进的地方。

在大文件的测试中 DBFS 没有表现出非常优秀的性能，但因为数据库具有自己的缓存机制，这使得在小文件的测试中 DBFS 是可以具有与 ext 系列相同的性能的。同时，因为数据库具有事务特性，因此 DBFS 中原生地也会支持事务特性。这个特性可以保证用户的数据被安全地存储而不会丢失。

5.6 Filebench

Filebench 是一个基准测试工具，用于评估文件系统和存储系统的性能。它可以模拟各种应用程序的工作负载，包括 Web 服务器、邮件服务器、数据库服务器、多媒体应用程序等。Filebench 支持多种文件系统。其基于脚本的工作方式，让用户可以使用脚本来描述测试场景和工作负载。用户可以使用 Filebench 提供的预定义脚本，也可以创建自己的脚本来模拟自定义的工作负载。

在本文中，主要使用 Web 服务器、邮件服务器、文件服务器对文件系统进行了测试。在 web 服务器中，其目标是模拟简单的网络服务器 I/O 活动。主要的操作是在目录树中的多个文件上生成一系列打开-读取-关闭以及日志文件追加。默认使用 100 个线程。在邮件服务器中，其目标是模拟将每封电子邮件存储在单独文件 (/var/mail/server) 中的简单邮件服务器的 I/O 活动。工作负载由单个目录中的一组多线程执行创建-追加-同步、读取-追加-同步、读取和删除操作。默认使用 16 个线程。生成的工作负载与 Postmark 有点相似。在文件服务器中，其目标是模拟简单的文件服务器 I/O 活动。此工作负载对目录树执行一系列创建、删除、附加、读取、写入和属性操作。默认使用 50 个线程。生成的工作负载有点类似于 SPECsfs。

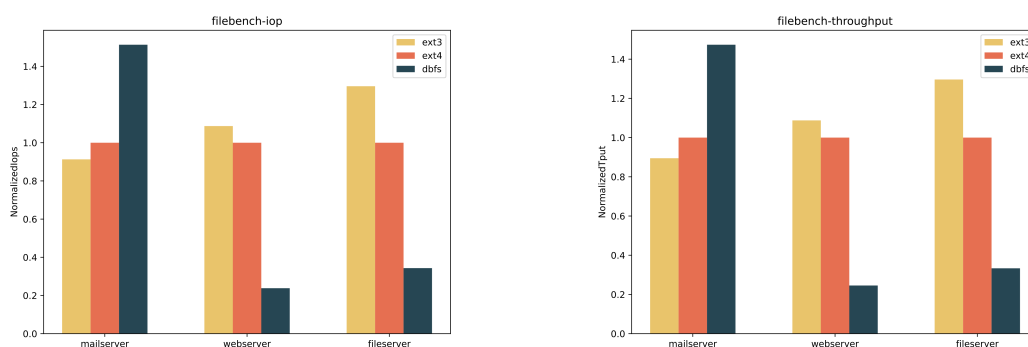


图 5-5 Filebench 测试结果

图5-5显示了测试结果。在 filebench 的测试中，ext 文件系统在 web 服务器与文件服务器的吞吐量和 IOP 上相比 DBFS 具有领先优势，在 mailserver 中，DBFS 相较于两者具有领先优势。

对于这几种工作负载，其更多的操作集中在元数据的处理上，而前文中提到，在 ext 文件系统的 fuse 实现中，对于元数据有针对性的优化，同时，这两种文件系统对并发也有较好的支持，两者的读性能也优于 DBFS，因此在 web 服务器和文件服务器中 ext 的性能会遥遥领先。在邮件服务器中，之所以 DBFS 具有一定的领先优势，这里主要是因为邮件服务器中所有文件大小总共才占据 1.5GB 的大小，而这个大小足以让操作系统将文件数据缓存到内存中，在 DBFS 中，数据库的读事务发生时读取的是内存映射区域，因此文件内容全部被加载到缓存中大大减少 DBFS 的页交换次数，从而在一定程度上缓解了其性能损失。

filebench 的测试进一步说明了 DBFS 的优势集中在小文件存储、文件搜索、目录查询等操作上，在物理内存容量较大的服务器端，DBFS 可以表现出更好的性能。

5.7 Alien OS 的性能测试

本文不仅将 DBFS 移植到 Alien OS 中，为了可以更直接查看内核中 DBFS 的性能，还移植了一个 fat32 文件系统，因为 Alien OS 中有一个类似 linux 的 VFS，因此 fat32 的移植会比较简单。本文编写了几个测试程序以测试两个文件系统是否正确工作，实验证明确实如此。在实现正确的基础上，本文编写了几个读写测试的程序。在顺序写测试中本文写入 10MB 大小的数据，在第一次写入时，DBFS 会处理缺页异常将磁盘块的内容加载到内存中，fat32 同样也会加载数据到内存中。在顺序读中，先写入 10MB 大小的数据，再将数据顺序读出。在随机读写测试中，首先写入 16MB 大小的数据，随后进行 1000 次的随机读取操作和 1000 次的随机写操作。

表 5-2 Alien OS 测试结果

(MB/s)/FS	DBFS	FAT32
顺序写 (1MB)	32MB/s	15MB/s
顺序写 (Re)	384MB/s	104MB/s
顺序读 (1MB)	1000MB/s	110MB/s
顺序读 (4KB)	27MB/s	50MB/s
随机写 (1MB)	386MB/s	56MB/s
随机读 (1MB)	1066MB/s	58MB/s

表5-2显示了在 Alien 中对 DBFS 和 FAT32 进行测试的结果。在读写大小 1MB 的情况下，DBFS 相对于 FAT32 各种读写都具有较大的优势。其中顺序写最大是 FAT32 的 4 倍，顺序读最大是 FAT32 的 10 倍。DBFS 的随机读写性能几乎保持各自保持一致。在读写大小为 4K 的情况下，DBFS 的性能会下降，在顺序读稍弱于 FAT32。

对于 DBFS 来说，本文设定了其存储粒度为 32kb 大小，在读写大小为 1MB 的情况下，每次读取只会查找 32 个键值对就可以完成数据读取，而对于 fat32 来说，由于其存储粒度只能设置为 512B，因此读取时需要依次访问数千个块，这让 1MB 大小下 DBFS 具有更好的性能。当读写大小为 4kb 的情况下，数据库读取虽然每次只

需要查找一个键值对，但总体的读取次数达到了数千次，频繁的索引反而降低了其性能，而对于 FAT32, 其数据几乎是连续存储，每次读取都只需要在前一次的基础上继续，综合下来，就导致了 DBFS 的性能下降。在表中第一行与第二行表现出不同的性能数据，这是因为第一行的测试是首次写入两个文件系统，因此内核会将磁盘数据加载到内存中，而第二行的写就只会在内存中完成。在随机读写中，DBFS 表现出了与顺序读写相同的性能，而 fat32 性能下降了一半左右，因为 fat32 在随机读写中需要频繁地在分配表中线性查询数据位置，而 DBFS 依靠数据库的高效索引和特殊的设计，即使是随机读写，也同样具有更快的查找速度。

5.8 小结

本节对 DBFS 的实现进行了性能测试和分析，在 linux 系统上，本文使用多个标准的测试工具和应用对 DBFS 的 fuse 实现做了比较详尽的测试，同时与 ext3 和 ext4 进行了对比。由于毕业设计时间有限，目前的性能尚不是非常理想，但通过分析未来可以对其进行优化改进。在 Alien OS 中，本文将 DBFS 与 FAT32 进行了对比，实验证明，其性能相较于 FAT32 具有较大的优势，并且在随机读写中依然拥有和顺序读写相同的性能。

结 论

随着计算机科学的发展，文件系统作为操作系统的核心组成部分，一直在不断地发展和演变。现代文件系统通过提供高效的数据组织和存储、可靠的容错能力和高级功能（如数据压缩、快照和镜像等）来满足不同的需求。但是，这些功能的实现通常需要复杂的算法和数据结构，并且有时需要对硬件进行特殊的优化。此外，文件系统的开发和维护也需要大量的时间和精力，现代文件系统愈加复杂，导致难以调试和纠错。数据库是一种高效、可靠且具有事务特性的数据管理系统，现实世界对数据的需求不断变化，也让数据库的发展不断更新迭代，总体而言，数据库的发展速度要远远快于文件系统。在文件系统中许多新技术都借鉴自数据库系统。传统的文件系统实现方式在近几十年的发展过程中并没有发生本质性的变化，并且在从数据库系统中引入一些特性时还需要不断地进行修改与适配，这导致了許多不必要的成本。为了解决这些问题，本文考虑利用数据库来作为数据引擎实现文件系统。基于数据库的文件系统的可以带来很多好处，例如，数据库提供了高效的查找算法和缓存机制，可以加快文件访问速度；同时，数据库也提供了高级特性，比如备份，事务等。此外，使用数据库还可以简化文件系统的实现，使得开发者不再需要关注在磁盘上的具体布局，不需要重复编写数据库中已经具备的功能，提高代码的可维护性和可扩展性。

本文对基于数据库的文件系统进行初步尝试，设计并实现了一个操作系统无关的 DBFS。本文选择了一个简单的 key-value 类型的数据库 jamddb 作为底层的数据库引擎，并对数据库进行改造去除对操作系统的依赖，在此基础上，根据数据库的结构设计了类似于 ext 系列的超级块、Inode 等数据结构，并参考 linux 的 VFS 提供了一层与系统无关的文件操作函数。在 linux 系统上，本文将 DBFS 接入 fuse，从而可以在 linux 系统上完成文件系统的功能验证和性能测试。同时，为了验证使用 rust 编程语言实现的 DBFS 可以迁移到 linux 内核中，本文使用 rust 实现了一个类 linux 的简易操作系统内核 Alien OS，并将 DBFS 无缝地迁移到此内核中。

评估结果表明，本文的 DBFS 实现符合 POSIX 文件系统语义，并通过了其 92% 的测试。在元数据密集型测试中 DBFS 充分利用了数据库的高效数据结构，在文件查找、目录搜索等操作上达到了与常见的 ext 文件系统同一水平，DBFS 同样将数据

库的事务特性融入到文件系统实现当中，使其在一些原子性操作上领先常见的文件系统。在读写性能测试中，得益于数据库的缓存机制，DBFS 也有不错的表现。除了在测试中表现出的优势，DBFS 还具有许多的潜在的好处，其一文件系统天然地拥有了数据库的事务特性，这进一步增强了文件系统的安全性和数据保障，使得用户不再担心数据的丢失；其二数据库的接口不仅可用于文件系统，还可以直接导出到用户态供用户使用，这让数据库的能力得到了充分利用，也避免了用户对外部数据库的依赖。其三文件系统具有更大的灵活性，因为底层是数据库，因此想要在文件系统中添加功能可以不再陷入到一些低级的磁盘布局设计中，开发者可以在更高的层次上对文件系统进行统筹设计和实现。总体而言，基于数据库的文件系统在保证了同时具有文件系统和数据库功能的前提下，大大简化了文件系统的开发难度，提高了文件系统的可扩展性。

基于数据库的文件系统设计近年来并未得到广泛的关注，许多学者将大多数精力投入在移植数据库功能到文件系统中。本文的研究成果可以为后续基于数据库的文件系统的开发和研究打下坚实的理论和实践基础，同时可以探索数据库和文件系统有机结合的方案，充分将数据库的能力融入到文件系统中。

虽然本文的工作已经成功取得了初步成果，但仍然有很多改进的空间，未来的工作可以分为几个阶段：

1. 进一步探索 jammdb 数据库本身的设计与实现，通过分析数据库中潜在的性能瓶颈，改善 DBFS 的设计和实现，使得文件系统的性能进一步提升；
2. 选择更强大，更完善的数据库来实现基于数据库的文件系统，并提供与现代文件系统相当的性能和可靠性；
3. 在 DBFS 移植到 Alien OS 的基础上，进一步探索如何将 DBFS 完全移植到 Linux 内核中，而这里的核心是如何将数据库移植到内核中；
4. 探索如何将数据库的事务特性充分融合到操作系统当中；

参考文献

- [1] Irum I, Raza M, Sharif M, et al. File Systems for Various Operating Systems: A Review[J]. Research Journal of Applied Sciences, 2012, 4(17): 2934-2947.
- [2] Han J, E H, Le G, et al. Survey on NoSQL database[C]//2011 6th International Conference on Pervasive Computing and Applications. 2011: 363-366.
- [3] Junyan L, Shiguo X, Yijie L. Application Research of Embedded Database SQLite[C]//2009 International Forum on Information Technology and Applications: vol. 2. 2009: 539-543.
- [4] Best S. {JFS} Log: How the Journaled File System Performs Logging[C]//4th Annual Linux Showcase & Conference (ALS 2000). 2000.
- [5] Sweeney A, Doucette D, Hu W, et al. Scalability in the XFS File System.[C]//USENIX Annual Technical Conference: vol. 15. 1996.
- [6] Rodeh O, Bacik J, Mason C. BTRFS: The Linux B-tree filesystem[J]. ACM Transactions on Storage (TOS), 2013, 9(3): 1-32.
- [7] Cao M, Bhattacharya S, Ts'o T. Ext4: The Next Generation of Ext2/3 Filesystem.[C]//LSF. 2007.
- [8] Oh J, Ji S, Kim Y, et al. {exF2FS}: Transaction Support in {Log-Structured} Filesystem[C]//20th USENIX Conference on File and Storage Technologies (FAST 22). 2022: 345-362.
- [9] Kalita C, Barua G, Sehgal P. DurableFS: a file system for NVRAM[J]. CSI Transactions on ICT, 2019, 7(4): 277-286.
- [10] Olson M A, et al. The Design and Implementation of the Inversion File System.[C]//USENIX Winter. 1993: 205-218.
- [11] 张步忠. 基于数据库的一个文件系统的移植[D]. 苏州大学, 2005.
- [12] Wright C P, Spillane R, Sivathanu G, et al. Extending ACID semantics to the file system[J]. ACM Transactions on Storage (TOS), 2007, 3(2): 4-es.
- [13] Chen M S, Han J, Yu P. Data mining: an overview from a database perspective[J]. IEEE Transactions on Knowledge and Data Engineering, 1996, 8(6): 866-883.
- [14] Brodie M L, Ridjanovic D. On the design and specification of database transactions[G]//Readings in Artificial Intelligence and Databases. Elsevier, 1989: 185-206.
- [15] Lu H, Ng Y Y, Tian Z. T-tree or b-tree: Main memory database index structure revisited[C]//Proceedings 11th Australasian Database Conference. ADC 2000 (Cat. No. PR00528). 2000: 65-73.
- [16] Bernstein P A, Hadzilacos V, Goodman N, et al. Concurrency control and recovery in database systems: vol. 370[M]. Addison-wesley Reading, 1987.
- [17] Ward B. How Linux works: What every superuser should know[M]. no starch press, 2021.
- [18] Galloway A, Lüttgen G, Mühlberg J T, et al. Model-checking the linux virtual file system[C]//Verification, Model Checking, and Abstract Interpretation: 10th International Conference, VMCAI 2009, Savannah, GA, USA, January 18-20, 2009. Proceedings 10. 2009: 74-88.
- [19] Kleiman S R, et al. Vnodes: An Architecture for Multiple File System Types in Sun UNIX.[C]//USENIX Summer: vol. 86. 1986: 238-247.
- [20] Malkhi D, Terry D. Concise version vectors in WinFS[J]. Distributed Computing, 2007, 20(3): 209.
- [21] Murphy N, Tonkelowitz M, Vernal M. The design and implementation of the database file system [Z]. 2002.

- [22] Kashyap A, Kashyap A. File system extensibility and reliability using an in-kernel database[D]. Stony Brook University, 2004.
- [23] Muthitacharoen A, Chen B, Mazieres D. A low-bandwidth network file system[C]//Proceedings of the eighteenth ACM symposium on Operating systems principles. 2001: 174-187.
- [24] Matsakis N D, Klock F S. The rust language[J]. ACM SIGAda Ada Letters, 2014, 34(3): 103-104.
- [25] Jung R, Jourdan J H, Krebbers R, et al. RustBelt: Securing the foundations of the Rust programming language[J]. Proceedings of the ACM on Programming Languages, 2017, 2(POPL): 1-34.
- [26] Chen S F, Wu Y S. Linux Kernel Module Development with Rust[C]//2022 IEEE Conference on Dependable and Secure Computing (DSC). 2022: 1-2.
- [27] Bell M R, Engleka M J, Malik A, et al. To fuse or not to fuse: what is your purpose?[J]. Protein Science, 2013, 22(11): 1466-1477.
- [28] Rajgarhia A, Gehani A. Performance and extension of user space file systems[C]//Proceedings of the 2010 ACM Symposium on Applied Computing. 2010: 206-213.
- [29] Tarasov V, Bhanage S, Zadok E, et al. Benchmarking File System Benchmarking: It* IS* Rocket Science.[C]//HotOS: vol. 13. 2011: 1-5.
- [30] Traeger A, Zadok E, Joukov N, et al. A nine year study of file system and storage benchmarking[J]. ACM Transactions on Storage (TOS), 2008, 4(2): 1-56.
- [31] Yang J, Twohey P, Engler D, et al. Using model checking to find serious file system errors[J]. ACM Transactions on Computer Systems (TOCS), 2006, 24(4): 393-423.

附 录

附录 A linux 环境下 DBFS 的 fuse 使用

DBFS 是一个 rust 项目，其 github 地址为dbfs2. 在 linux 环境下，请安装 rust 工具链，并拉取仓库到本地，按照项目 README 中描述获取 DBFS 相关内容和运行方式。

附录 B Alien OS

Alien OS 也是一个 rust 项目，其 github 地址为Alien.Alien OS 运行在 qemu 模拟的 riscv 平台上，因此想要运行 Alien 需要安装 Qemu、riscv 工具链等。具体的内容请查看仓库的项目描述。

附录 C Fio 测试数据

表 C-3 Fio 单线程测试结果

	顺序写	顺序读	随机写	随机读
EXT4	116MB/s	268.5MB/s	70MB/s	155MB/s
EXT3	385MB/s	301.5MB/s	376MB/s	195MB/s
DBFS	350MB/s	41MB/s	227MB/s	40MB/s

表 C-4 Fio 多线程测试结果

	顺序写	顺序读	随机写	随机读
EXT4	135MB/s	351MB/s	78MB/s	230Mb/s
EXT3	397MB/s	370MB/s	393MB/s	280MB/s
DBFS	360MB/s	41MB/s	241MB/s	39MB/s

表 C-5 filebench 测试

	DBFS	EXT3	EXT4
fileserver	784ops/s 18.4MB/s	2960ops/s 70MB/s	2284ops/s 54MB/s
webserver	2573ops/s 13.6MB/s	11751ops/s 62.3MB/s	10808ops/s 57.3MB/s
mailserver	836.593ops/s 2.8MB/S	504.671ops/s 1.7MB/s	552.815ops/s 1.9MB/s

致 谢

值此论文完成之际，首先向我的导师表达我最深挚的感谢和真诚的敬意。在大三年级，是您将我带进操作系统的大门，让我对系统研究领域产生了极大的兴趣。您在本科阶段给予了我无私的指导和支持，您的专业知识和丰富的经验对我产生了深远的影响。您不仅在后续的学术研究上给予我耐心细致的指导，还教会了我如何进行科学思考和解决问题的能力。您的教诲和激励使我不断超越自我，并且在学术领域取得了长足的进步。感谢您对我毕业设计的认真审阅和指导，让我能够完成这一重要的学术任务。

其次，我要特别感谢我的室友。在这段时间里，我们共同面对了新冠疫情带来的挑战和困扰。疫情使得我们的学习和生活方式发生了巨大变化，但是在这个特殊时期，您们给予了我巨大的支持和鼓励。我们一起度过了艰难的时刻，相互支持、相互鼓励，共同克服了困难，取得了优异的学业成绩。您们的友谊和陪伴让我的大学生活更加充实和有意义。

最后，感谢我的父母。你们是我人生道路上最坚实的支持和依靠。从我踏入大学的那一刻起，你们就始终默默地支持着我，给予我无尽的鼓励和爱。你们为我提供了舒适的家庭环境和良好的成长条件，使我能够专心学业，并追求自己的梦想。无论我面临多大的困难和挑战，你们总是在我身边，给予我坚定的支持和智慧的指导。是你们的辛勤付出和无私的爱，让我成长为今天的自己。谢谢你们，我无法用言语表达我对你们的感激之情。

再次衷心感谢老师、同学们的支持和帮助。我相信，在你们的引导下，我将继续不断学习和进步，为实现自己的梦想努力奋斗。衷心祝愿你们在未来的工作和生活中一切顺利，取得更大的成就，也希望我的父母身体健康。